생활습관 분석 기반 맞춤 영양 개선 서비스

머신 2 러닝

양대천, 박준혁, 전유환, 최지연, 황재준

건강정보는 많지만, 실천은 쉽지 않습니다.



아프지 않고 오래 살려면 딱 '이 3가지'만 기억하세요. (김주환 교수 3부)

949만 • 3년 전

지식인사이드

[2026년 신체건강 인식조사] 미뤄지는 건강관리 – 건강관리의 우선순위와 실천 현황, 관리 장벽

사회

'시간 빈곤' 대한민국, 일하고 애보느라... 국민 13% '운동 전혀 안한다'

입력 2026-03-27 13:30:00

많은 건강정보 중, 나에게 필요한 것은?

익숙한 건강 조언

"식사는 규칙적으로"

"운동은 꾸준히"

"수면은 충분히"

내 생활에서는

무엇부터

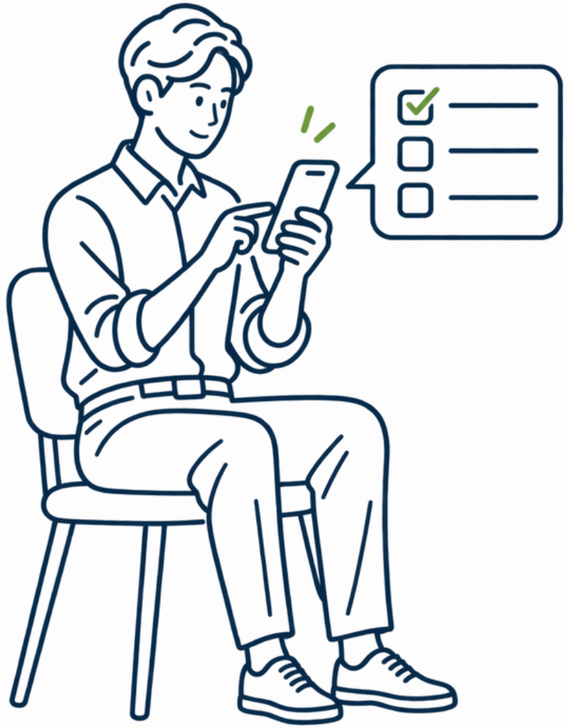
살펴봐야 할까?

우리의 생활습관은
영양과 어떻게 연결될까?



서로 다른 일상,
영양 상태에서도
차이가 나타날까?

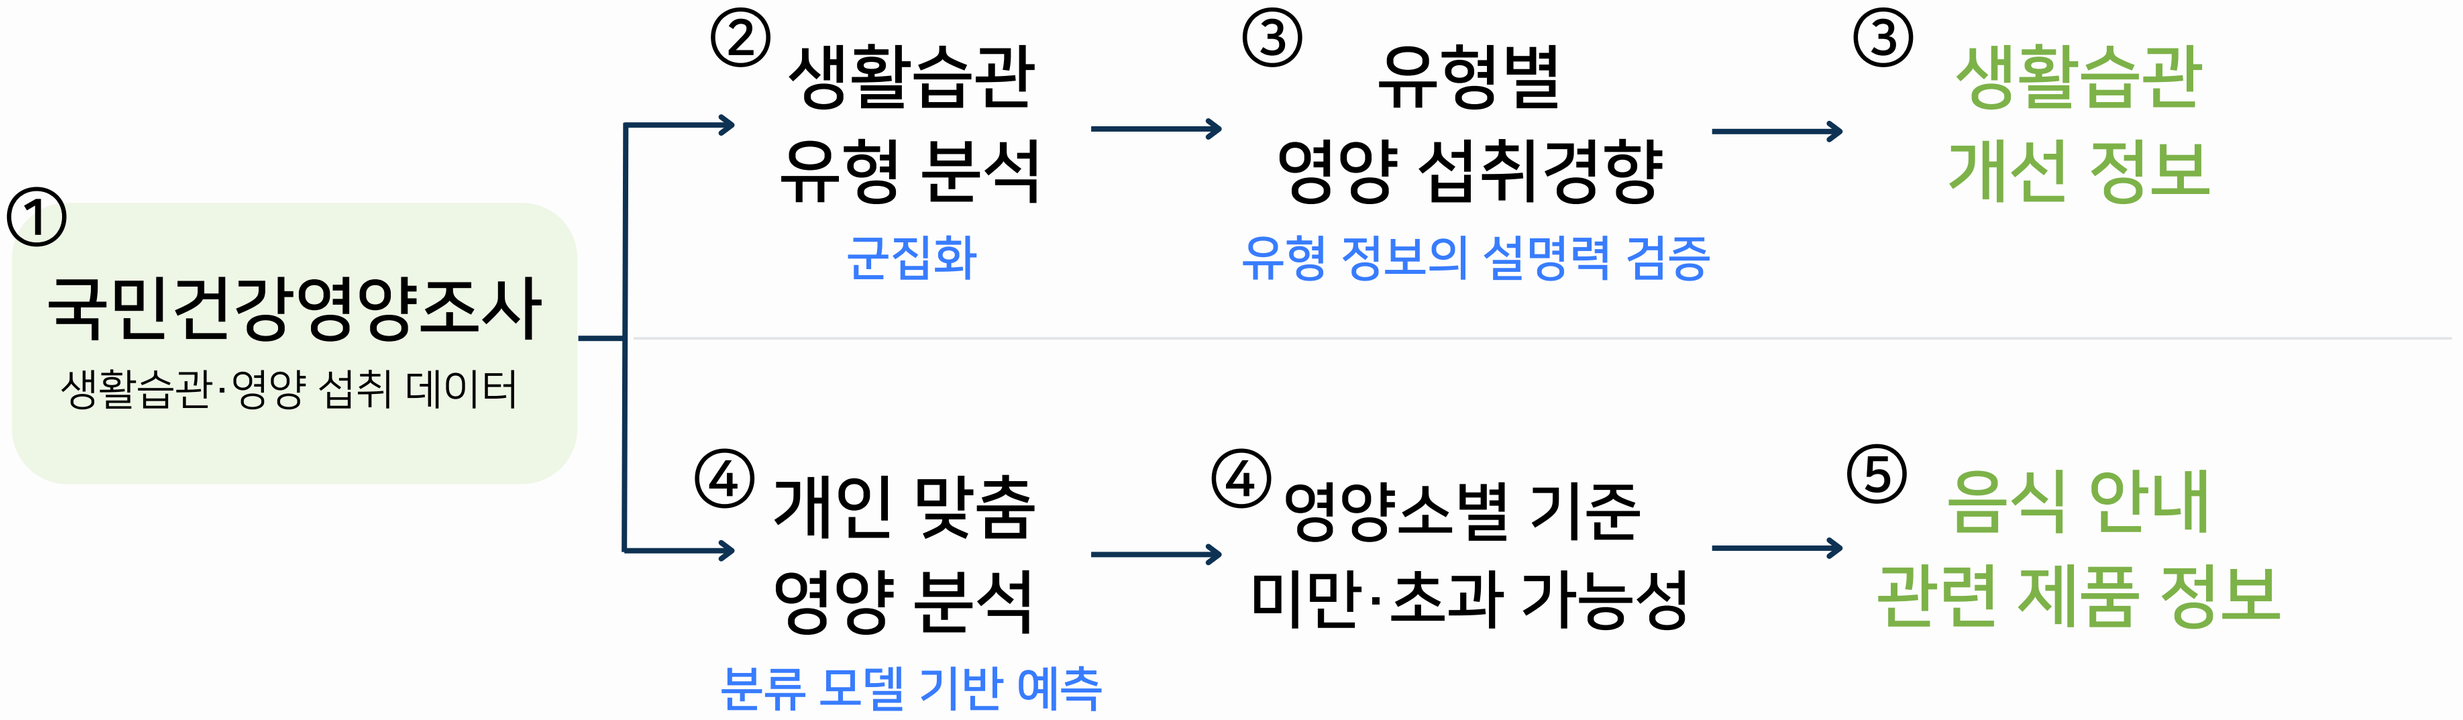
우리가 만들고자 한 서비스



가볍게 시작하는
나의 생활습관·영양 점검

간단한 설문으로 내 생활습관을 돌아보고,
챙겨볼 영양과 실천할 개선안을 확인합니다.

전체 분석과 서비스 흐름


①
국민건강영양조사
생활습관·영양 섭취 데이터
② 생활습관 유형 분석
군집화
③ 유형별 영양 섭취경향
유형 정보의 설명력 검증
③ 생활습관 개선 정보
④ 개인 맞춤 영양 분석
분류 모델 기반 예측
④ 영양소별 기준 미만·초과 가능성
⑤ 음식 안내 관련 제품 정보

머신러닝을 선택한 이유

01 생활습관 유형화

비슷한 생활패턴은 무엇일까?

생활습관 응답 → 생활습관 유형

군집화 · 비지도학습

02 개인별 영양 예측

이 사람은 무엇을 점검해야 할까?

X 개인 설문 응답
y 기준 미만·초과 여부

→ 새 사용자의 미만·초과 가능성

분류 모델 · 지도학습

01

데이터 소개 및 전처리

분석에 사용한 데이터

데이터	포함 자료	프로젝트에서의 역할
국민건강영양조사	2022~2024년 통합 자료 2012~2016년 통합·FFQ 자료	생활습관 유형 분석 및 개인별 영양 예측
2025 한국인 영양소 섭취기준	성별·연령별 영양소 섭취기준	섭취량과 비교해 학습용 정답 생성 · 제품 상한섭취량 확인
건강기능식품 품목제조 신고	식약처 품목제조 신고사항 (C003)	제품 분류·필터링 및 후보 선정
1일 영양성분 기준치	영양성분 기준치 자료 · 기능성 원료 인정 섭취량	제품의 영양성분 함량 해석 · 생활기능 영양제 함량 확인

국민건강영양조사 자료 구성



분석을 위한 데이터 전처리

1

변수 선택 및 결측 처리

분석에 필요한 컬럼 선택
결측·모름 응답 처리

2

응답값 보정

끼니·외식 응답 방향 수정
연도별 수면 측정 차이 보정

3

군집화용 변수 구성

세 끼 빈도를 규칙식사 점수로 통합
변수별 척도를 맞추기 위한 표준화

02

생활습관 유형 분석

군집화에 검토한 생활습관 변수

활동·휴식·식사·흡연·음주를 포함한 후보 변수 14개 검토

영역	후보 변수	개수
활동	유산소운동 · 근력운동	2개
휴식·스트레스	좌식시간 · 수면시간 · 스트레스 인지	3개
식사	아침·점심·저녁 식사 빈도 · 외식빈도	4개
흡연·음주	흡연·음주 관련 응답 변수	5개

14개는 후보 변수이며, 최종 군집화에는 다음 장의 7개 변수를 사용

군집화 변수 선택 근거

흡연·음주 변수의 편중을 줄여 다양한 생활패턴 반영

후보 14개에서 최종 7개로 구성

후보 변수
14개

흡연·음주 변수 제외
→
식사 빈도 3개
→ 1개 통합

최종 변수
7개

군집 간 차이의 변화

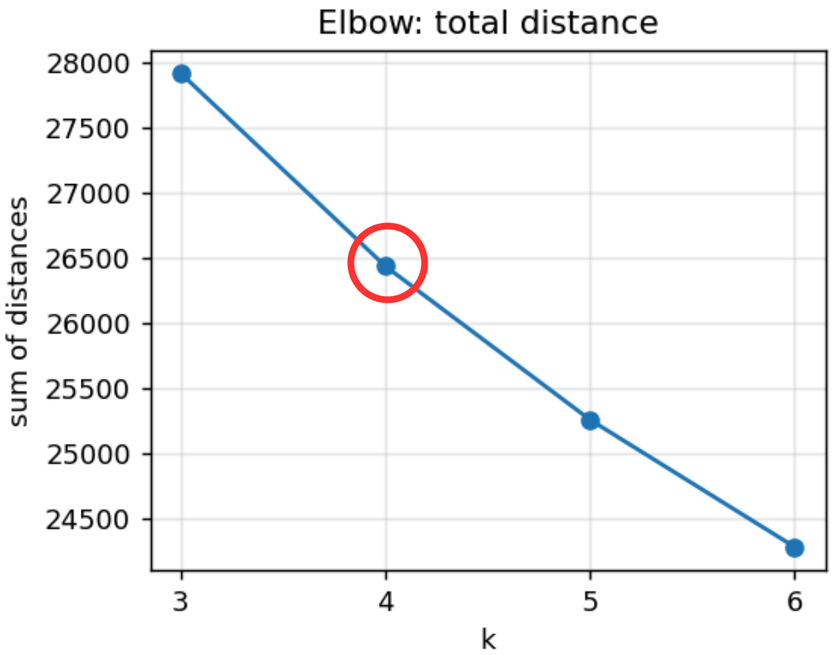
변수군	기존 군집 η^2	변경 후 군집 η^2
흡연·음주 포함 14개	0.731	0.027
최종 변수 7개	0.066	0.228

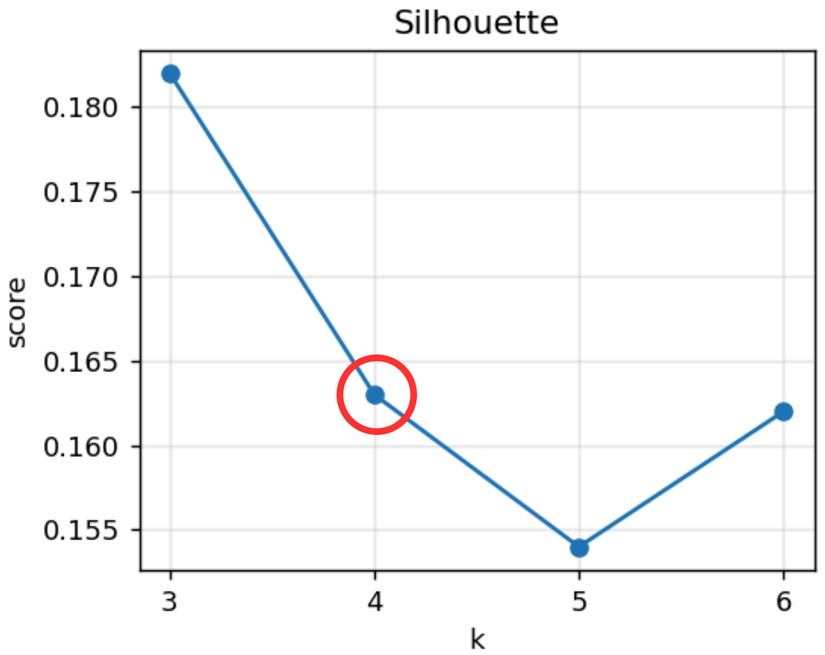
평균 η^2: 해당 변수에서 군집 간 차이가 나타나는 정도

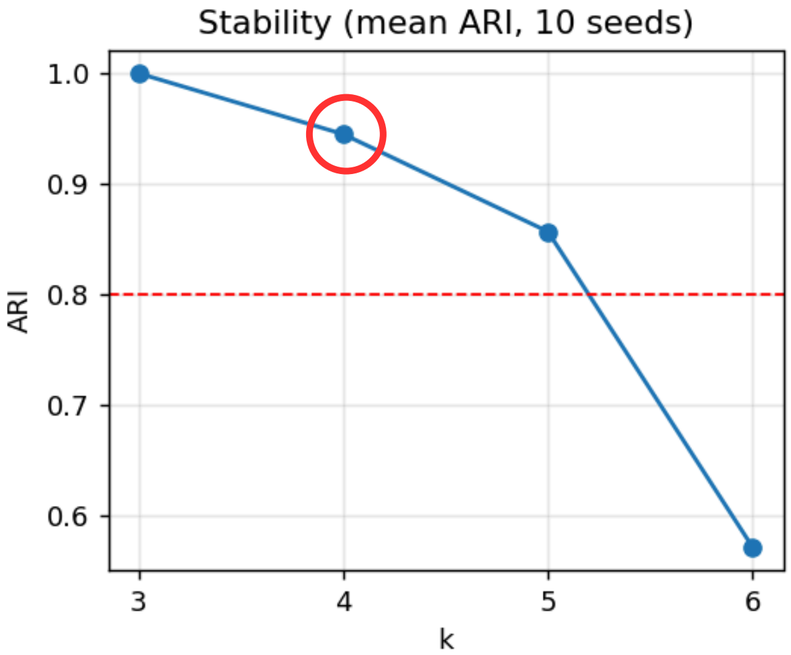
대분류 군집화

군집화(비지도 학습) K-medoids 알고리즘 사용 + PCA(5차원)

K = 4

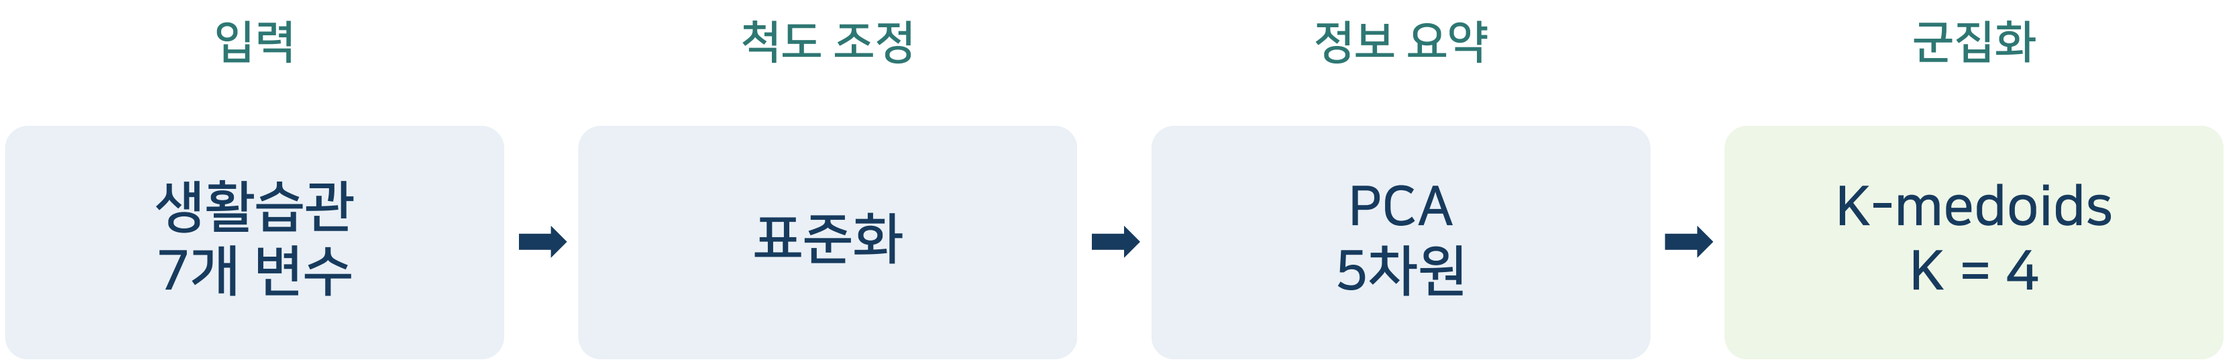






대분류 군집화

7개 생활습관 변수를 요약해 4개 대분류 도출



PCA · 주성분분석

여러 변수의 정보를
5개 축으로 요약

K-medoids · 대표 관측치 기반 군집화

각 군집을 대표하는 관측치를 중심으로
비슷한 생활패턴끼리 묶기

대분류 군집화 결과

활동·스트레스·좌식·식사 패턴에 따라 4개 유형으로 구분

비활동형

4,489명 · 29.8%

운동이 적은 생활패턴

운동 거의 없음
외식 빈도 낮음
수면시간이 긴 편

운동형

4,171명 · 27.7%

운동을 실천하는 생활패턴

유산소·근력 운동
좌식시간이 짧은 편
스트레스가 낮은 편

고스트레스형

3,444명 · 22.9%

스트레스와 불규칙한 식사

스트레스가 높은 편
수면시간이 짧은 편
불규칙한 식사

좌식·외식형

2,958명 · 19.6%

긴 좌식시간과 잦은 외식

좌식시간이 긴 편
외식 빈도가 높은 편
수면시간이 긴 편

대분류 안에서도 식사·운동 습관의 차이를 확인하기 위해 세부분류 진행

세부분류 군집화

각 대분류를 3개로 나눠 총 12개 세부유형 도출

대분류별로 구분에 활용한 변수

대분류	선정된 변수 조합
비활동형	외식빈도 + 식사 규칙성
운동형	근력운동 + 식사 규칙성
고스트레스형	유산소운동 + 근력운동
좌식·외식형	근력운동 + 식사 규칙성

후보 조합 검토

7개 변수의 56개 조합

세부 군집 수 K = 3

모든 대분류에서
최소 군집 비율 12% 이상

안정성·군집 크기·변수 기여·실루엣을 함께 검토한 기준은 참고 자료에 정리

생활습관 기반 12개 군집 유형

4개 대분류 안의 식사·운동 차이를 12개 유형으로 설명

비활동형	운동형	고스트레스형	좌식·외식형
N1 집밥좋아 나무늘보 외식 빈도 낮음 식사 규칙적	A1 뚜벅이 갓생러 유산소운동 식사 규칙적	S1 쉬고 싶은 예민보스 운동이 적은 편	O1 아침패스 워커홀릭 근력운동 적음 식사 불규칙적
N2 배고픈 나무늘보 외식 빈도 높음 식사 불규칙적	A2 파워 갓생러 근력운동 식사 불규칙적	S2 산책하는 예민보스 유산소운동이 많은 편	O2 삼시세끼 워커홀릭 근력운동 적음 식사 규칙적
N3 배부른 나무늘보 외식 빈도 높음 식사 규칙적	A3 밸런스 갓생러 근력운동 식사 규칙적	S3 쇠질하는 예민보스 근력운동이 많은 편	O3 운동하는 워커홀릭 근력운동 많음 식사 규칙적

03

유형별 영양 특성 분석

분석 목표와 가설

가설: 생활습관 유형에 따라 부족하기 쉬운 영양소가 다를 것이다

분석 목표

**생활습관 유형별로
다른 영양 안내**

가설 1	유형은 성별·연령대 외의 정보를 준다
가설 2	유형마다 더 부족한 영양소가 다르다
가설 3	고른 영양소는 다음 연도에도 맞는다

타겟 정의

지난 24시간 섭취량이 2025 KDRI 기준 미만이면 1

국민건강영양조사 9기 → 직전 24시간 섭취 → 영양소 섭취량 → 2025 KDRI 비교

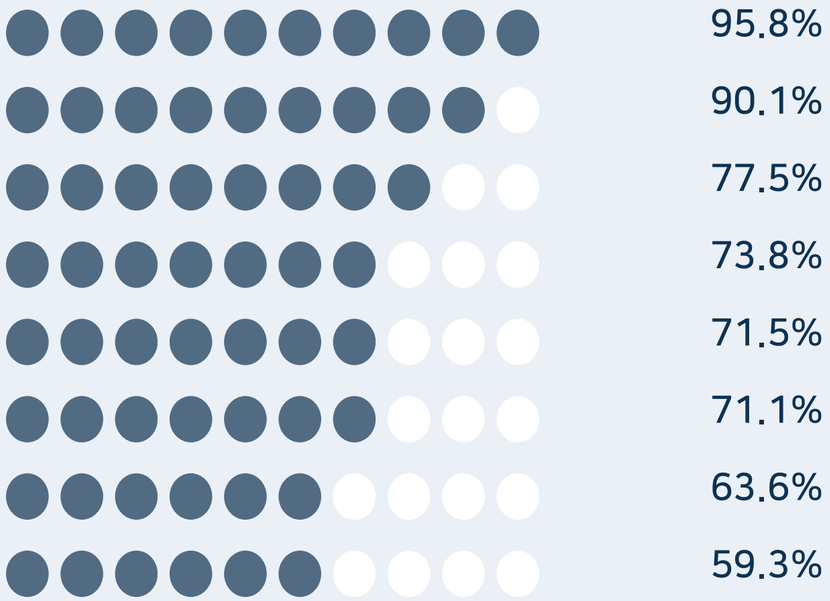
영양소 15개 → 기준 미만 = 1 · 기준 이상 = 0

EAR (평균필요량) 기준 · 11개	AI (충분섭취량) 기준 · 4개
단백질 · 비타민 A · 비타민 C · 티아민 · 리보플라빈 · 엽산 칼슘 · 마그네슘 · 철 · 아연 · 인	비타민 D · 비타민 E 칼륨 · 식이섬유

초기 분석의 문제

기준 미만 비율만 보면 모든 유형에서 같은 영양소가 선정됨

성인 기준 미만 비율 상위 8개



배고픈 나무늘보

- 비타민 D
- 비타민 E
- 칼륨

=

밸런스 갓생러

- 비타민 D
- 비타민 E
- 칼륨

유형을 구분하지 못함
→ 비교 기준 변경 필요

분석 기준 변경: 상대 비교

같은 성별·연령대 평균과 비교해 '특정 유형에서 더' 부족한 영양소를 찾음

부족 판단 기준 = 유형의 기준 미만 비율 ÷ 같은 성별·연령대 평균 비율

같은 성별·연령대 평균



0.4

이 유형



0.6

0.6 ÷ 0.4 = 1.5배 더 부족

모델 구성

유형 · 성별 · 연령대로 영양소 15개 각각의 기준 미만 확률을 예측

입력 x

생활습관 유형	12
성별	2
연령대	5

→

이진 분류 모델

영양소마다 1개 · 총 15개
조사 가중치 적용

→

출력 $\hat{y}$

P(기준 미만)

120개 조합
× 15개 영양소

영양소마다 후보 모델 10개

로지스틱 회귀	4
로지스틱 회귀 + 유형×성별 교호항	2
히스토그램 그래디언트 부스팅	4

모델 선택과 평가 설계

2022–23년 자료로 모델을 고르고, 2024년 자료로 평가

2022	2023	2024
모델 선택 · 9,742명		최종 평가 · 5,320명

5-fold 교차검증	학습 연도 안에서만
가중 로그 손실	확률 자체의 정확도
1-SE 규칙	차이가 오차 이내면 단순한 모델

비교 기준 모델

성별 + 연령대
로지스틱 회귀

→ 유형의 추가 효과 측정

최종 선택: 로지스틱 회귀 14개 + 그래디언트 부스팅 1개 (철)

가설 검증

검증 ①

정보

유형이 성별·연령대 외의
정보를 주는가

→

검증 ②

차이

유형마다 더 부족한
영양소가 다른가

→

검증 ③

재현

다음 연도에도
맞는가

→

**유형별
영양 안내**

검증 ① 유형 정보의 추가 효과

유형을 더하면 15개 중 13개 영양소에서 2024년 AUC 향상

2024년 AUC 향상 여부 (성별·연령대 모델 대비)

✓ 칼슘	✓ 비타민 A	✓ 마그네슘	✓ 리보플라빈	✓ 인
✓ 단백질	✓ 철	✓ 아연	✓ 비타민 C	✓ 엽산
✓ 식이섬유	✓ 티아민	✓ 칼륨	비타민 E	비타민 D

ΔAUC +0.014 ~ +0.040

비타민 D·E: 거의 모두 기준 미만이라 차이 없음

순열 검정 200회

+0.024 → −0.004 유형을 섞으면 효과 소멸

과적합

학습 – 평가 AUC ≤ 0.029

확률 보정

예측 – 실제 ≤ 1.7%p

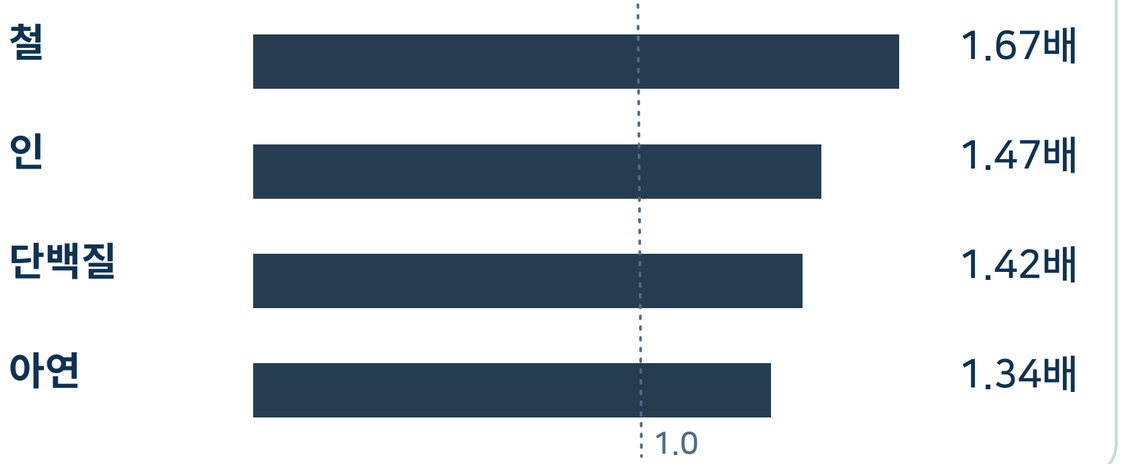
가설 1 지지

향상 폭은 작음 → 경향 안내로 사용

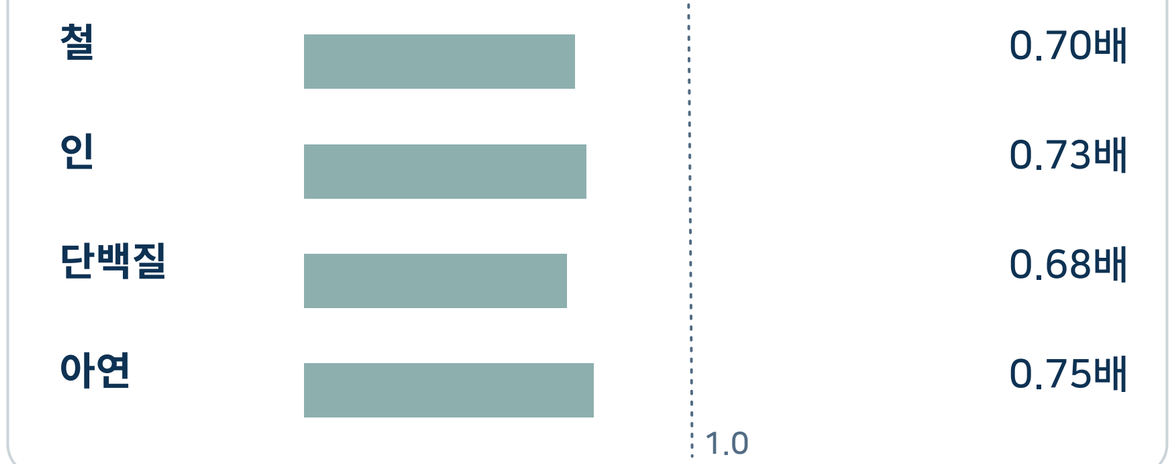
검증 ② 유형별 부족 배수

끼니를 거르는 유형은 더, 세 끼를 챙기는 유형은 덜 부족

배고픈 나무늘보
운동 적음 · 끼니를 자주 거름



밸런스 갓생러
근력 운동 · 세 끼 규칙적



같은 경향 더 부족: 아침패스 워커홀릭 · 쉬고 싶은 예민보스 덜 부족: 삼시세끼 워커홀릭 · 배부른 나무늘보

최종 안내 기준 수립

표시 규칙 3개를 120개 조합에 적용해 비교 → 2단 표시 채택

A 확률 ≥ 0.5

화면당 8~9개 나열

유형 차이가 묻힘

탈락

B 상위 3개

평균보다 덜 부족한데

'부족' 표시 158 / 360

탈락

C 2단 표시

공통 8개는 따로 안내

그 외: 확률 ≥ 0.5 또는
배수 ≥ 1.2 & 확률 ≥ 0.3

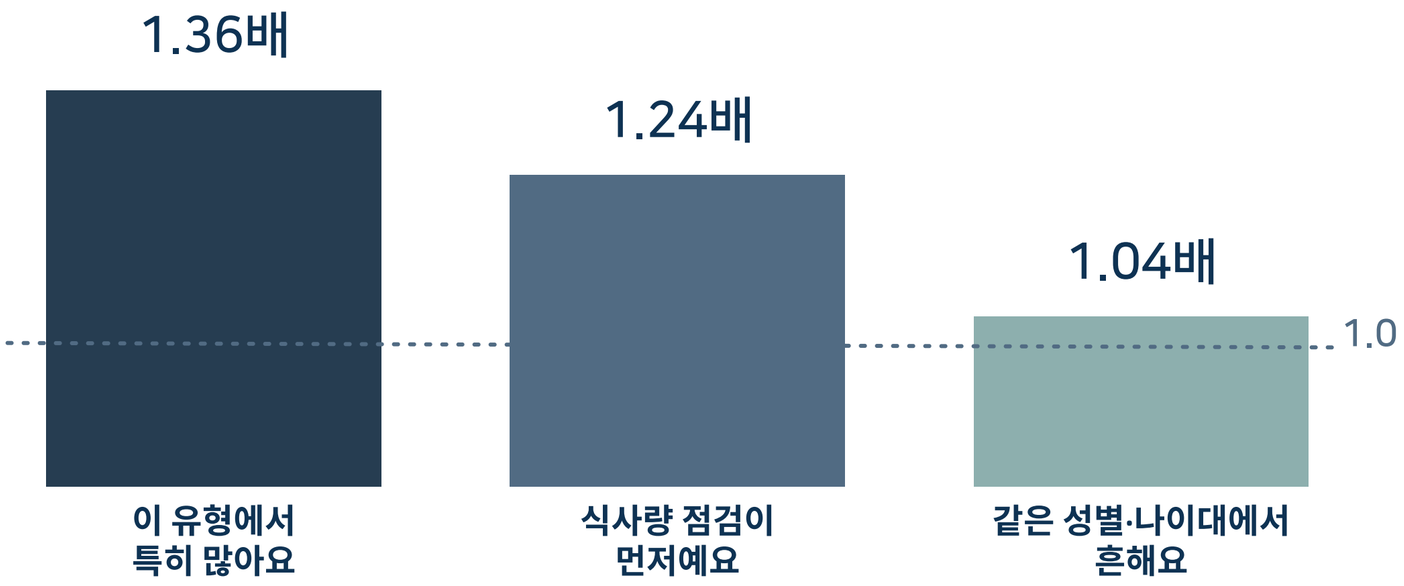
채택

기준값 1.2배 · 0.3은 결과를 보기 전에 팀 문서로 정하고 고정

검증 ③ 다음 연도 재검증

2022–23년으로 고른 영양소, 2024년에도 예상보다 1.09배 더 부족

화면 문구별 2024년 실제 / 예상 비율



전체

1.087배

95% CI 1.056 ~ 1.121

유형을 섞으면 1.00배

가설 3 지지
문구 강도 = 실제 차이 순서

정리

생활습관 유형별 영양 특성과 안내 기준을 마련

가설 1	유형은 성별·연령대 외의 정보를 준다	13 / 15 영양소 AUC 향상	지지
가설 2	유형마다 더 부족한 영양소가 다르다	1.3~1.7배 vs 0.7배	지지
가설 3	고른 영양소는 다음 연도에도 맞는다	2024년 1.087배	지지

산출물

12개 유형 × 15개 영양소 부족 배수
공통 / 유형별 2단 안내 기준 → 웹 유형 결과

해석 범위

24시간 회상 1일 · AUC 0.56~0.70
개인 진단이 아닌 같은 유형의 경향 안내

04

개인별 영양 위험 예측

개인 예측의 입력과 정답

설문 응답과 섭취기준 판정의 관계를 학습해 개인별 가능성 예측

01 학습 단계

입력 X

개인 설문 응답

성별·나이 + 생활습관
또는 식품빈도 응답

+

정답 y

섭취기준 판정

조사된 섭취량을 기준과 비교
영양소별 기준 미만·초과 여부

→

영양소별 모델 학습

입력과 정답의
관계를 학습

02 사용 단계

새 사용자의 설문 응답 → 학습된 모델 → 영양소별 기준
미만·초과 가능성

예측 알고리즘의 작동 방식

응답별 가중치를 조합하거나, 여러 나무로 오차를 보완해 확률 계산

Logistic Regression

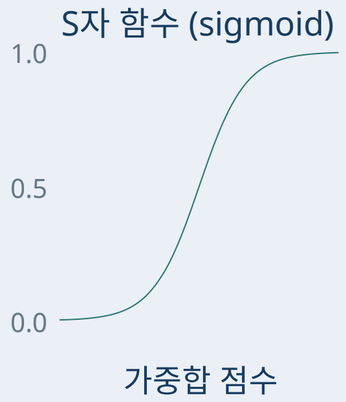
나이

식품 섭취빈도

그 밖의 응답

> **가중합**
> 가중치 × 응답
> + 절편

>



응답 → 가중합 점수 → 0~1 사이의 예측확률

Histogram-based Gradient Boosting

나무 1

응답 조건

보정값 보정값

초기 점수 보완

>

나무 2

응답 조건

보정값 보정값

남은 오차 보완

>

나무 3

응답 조건

보정값 보정값

다시 남은 오차 보완

초기 점수 + 나무별 보정값 → 확률 변환

생활습관 모델의 개선 과정

변수 추가·지식증류의 개선 폭이 작아, 식품정보 활용 검토

생활습관 설문 기반 초기 개선 실험

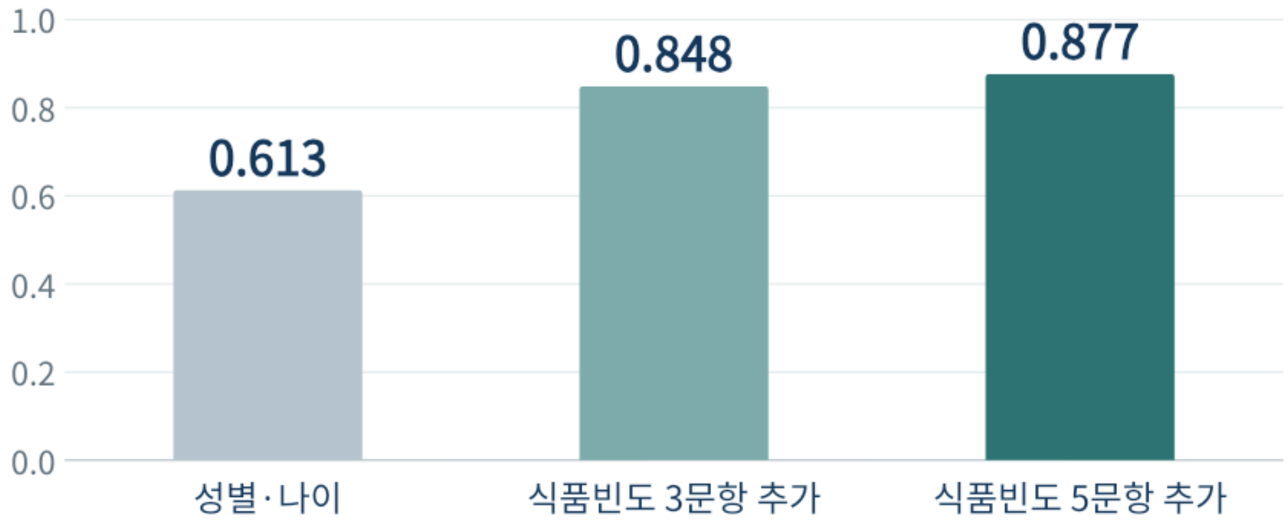
개선 시도	평균 ROC AUC	기본 모델 대비
기본 설문 모델	**0.658**	**기준**
파생변수 추가	0.656	−0.002
생활유형 추가	0.657	−0.001
지식증류 적용	**0.664**	**+0.006**

영양소 7개 평균 · 2022~2023년 학습 / 2024년 평가

식품빈도 문항의 도입

식품빈도 5문항 추가로 평균 AUC 0.877 달성

입력 정보에 따른 예측 성능



영양소 10개 평균 ROC AUC · 높을수록 구분 성능 우수

같은 FFQ 자료 내 비교 · 2012~2015년 학습 / 2016년 평가

FFQ · 식품섭취빈도조사

Food Frequency Questionnaire

평소 어떤 식품을
얼마나 자주 먹는지 조사

활용한 5개 식품군

육류 · 생선·해산물 · 달걀
콩류 · 유제품

5문항 구성 채택

성별·나이와 함께 예측에 활용

최종 모델 구성

생활습관과 식품빈도를 각각 학습한 두 모델로 개인별 영양 예측

구분	생활습관 모델	평소 식사 모델
입력	성별·나이 포함 생활습관 18개 변수	성별·나이 + 식품빈도 5문항 총 7개 변수
알고리즘	HistGradientBoosting 13개 Logistic Regression 1개 (비타민 C)	Logistic Regression 10개
예측 대상	**영양소 14개**	**영양소 10개**
출력	영양소별 기준 미달·초과 가능성	영양소별 기준 미달·초과 가능성

최종 예측 성능

학습에 사용하지 않은 연도 자료로 최종 예측 성능 확인

평가 항목	생활습관 모델	평소 식사 모델
평균 ROC AUC ↑	**0.6644**	**0.8766**
평균 PR AUC ↑	0.6205	0.7504
평균 Brier 점수 ↓	0.1906	0.1057
학습 / 평가 연도	2022~2023년 / 2024년	2012~2015년 / 2016년
평가 규모	5,320명 · 영양소 14개	3,370명 · 영양소 10개

↑ 높을수록 우수　↓ 낮을수록 우수

개인별 영양 분석 결과

개인 응답에 따라 영양소별 기준 미만·초과 가능성을 안내

영양소별 실제 웹 출력 예시

생활습관 응답 기반

마그네슘 기준 미만 가능성 높은 편

생활습관 응답으로 예측했어요

×

평소 식사 응답 기반

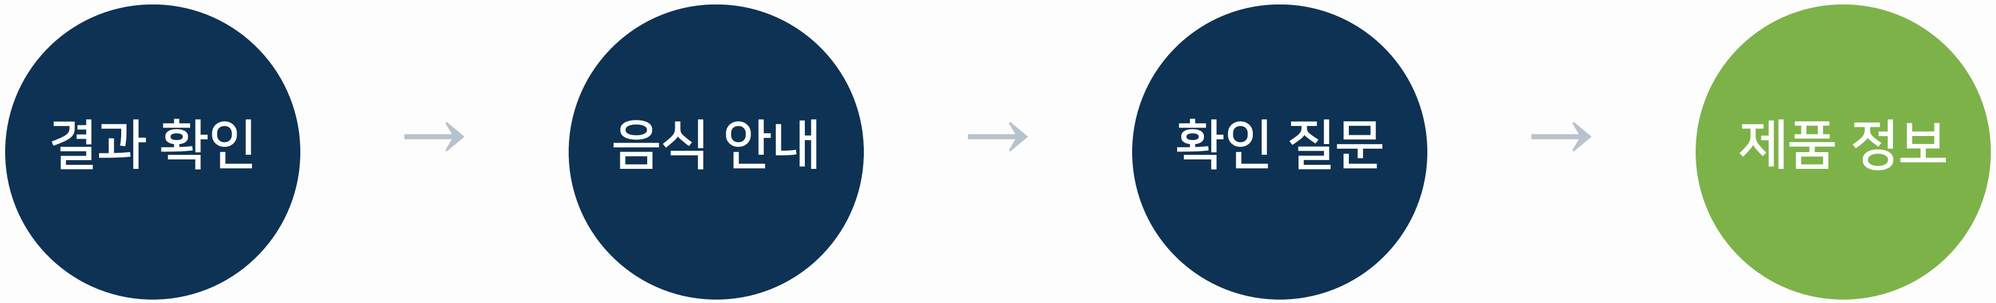
나트륨 기준 초과 가능성 높은 편

평소 식사 응답으로 예측했어요

05

맞춤 개선안 및 영양 정보 제공

결과에서 제품 정보까지



칼슘
기준 미만 가능성 높은 편

우유·두부·멸치
먼저 안내

임신·질환·복용약
있으면 전문가 상담

칼슘 제품 정보
함께 먹는 제품의 총함량 확인

음식으로 챙기는 영양소

나트륨

↓ 줄이기

기준 초과 가능성

- 국물 남기기
- 소스는 따로
- 성분표 확인

단백질·인

→ 고르게

기준 미만 가능성

- 끼니마다 단백질
- 세 끼 챙기기
- 간식은 견과·우유

건강기능식품 데이터

19,165개를 영양성분 중심과 생활기능 중심으로 나눠 각각 선별

식약처 건강기능식품
신고 자료

46,154건

19,165개

2022년 이후 · 국내 판매
대상 영양소 포함

영양성분 중심 제품

11개 분류

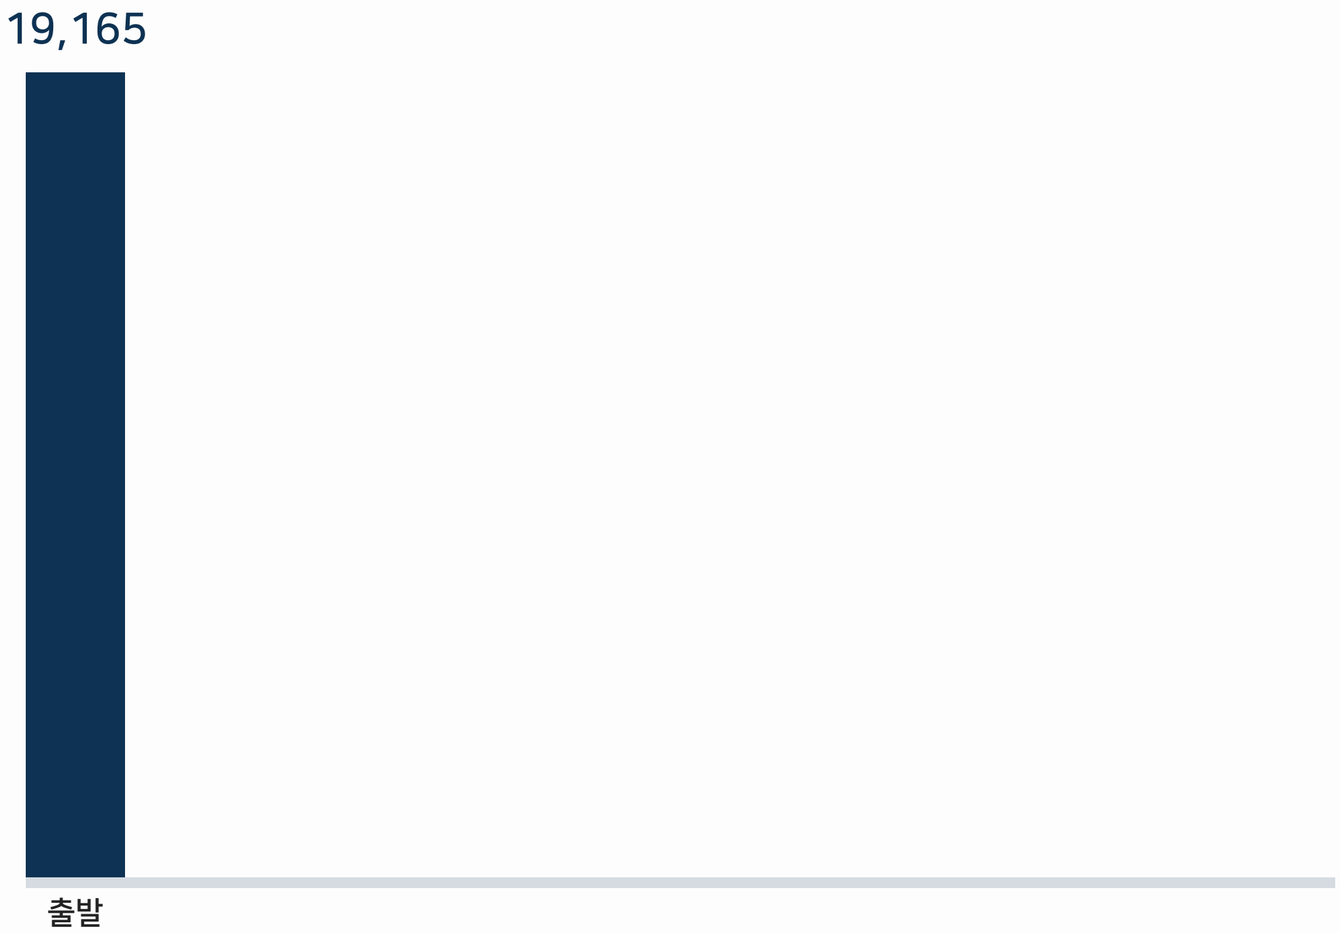
생활기능 중심 제품

4,577개 4개 분류

19,165개 중 따로 보관 · 일반 대상

출발

영양제 필터링 1 / 9



출발 제품 수

19,165

2022년 이후 신고

국내 판매 (수출·해외용 제외)

우리가 다루는 영양소가 든 제품

대상·질환

영양제 필터링 2 / 9



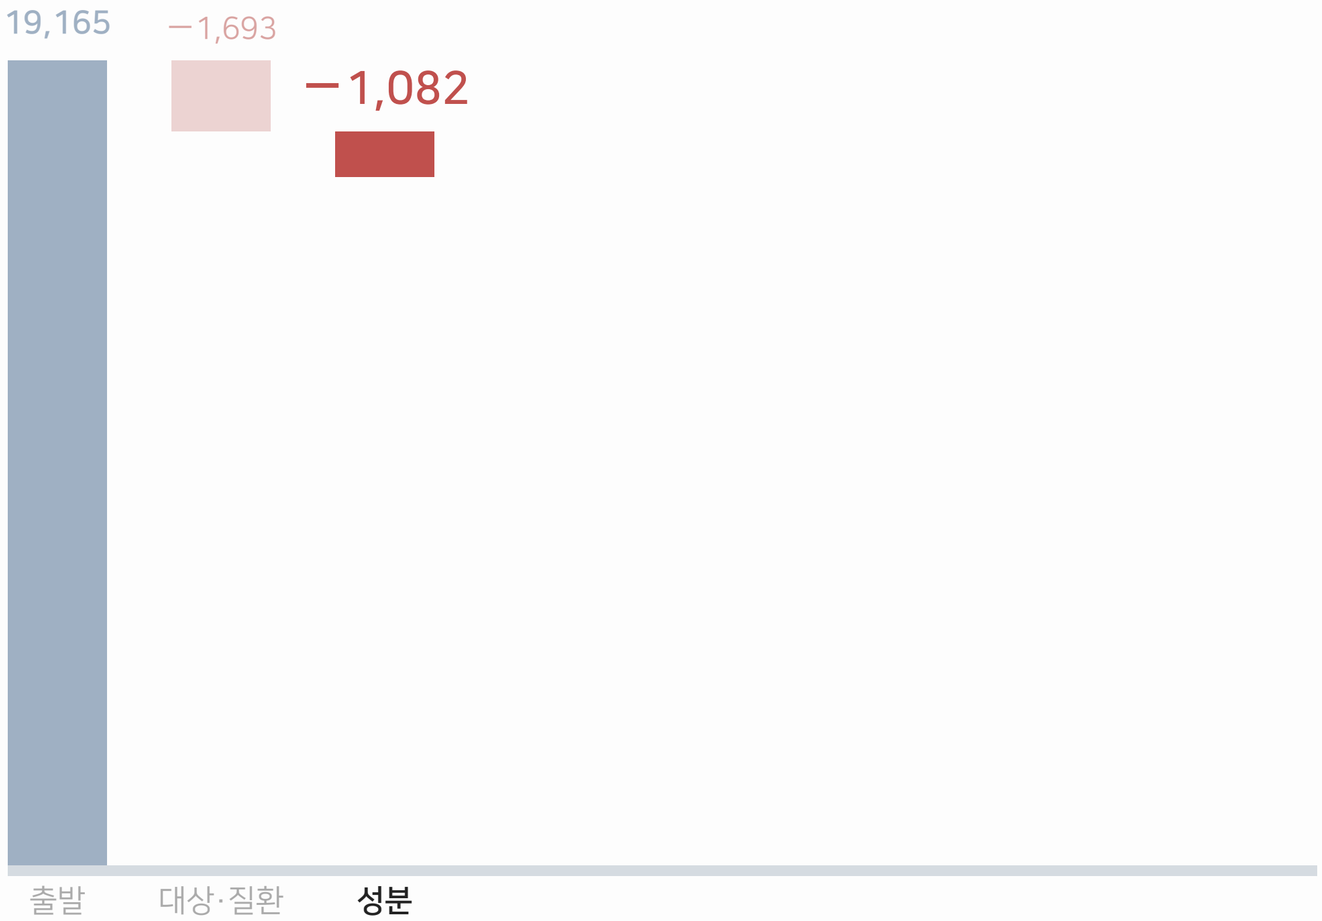
필터링 전

19,165 → 필터링 후 17,472

- 임산부·질환 제품명 제외
- 해외 판매용 제외
- 어린이용 제품 제외

주요 성분 및 제품 목적 확인

영양제 필터링 3 / 9



필터링 전

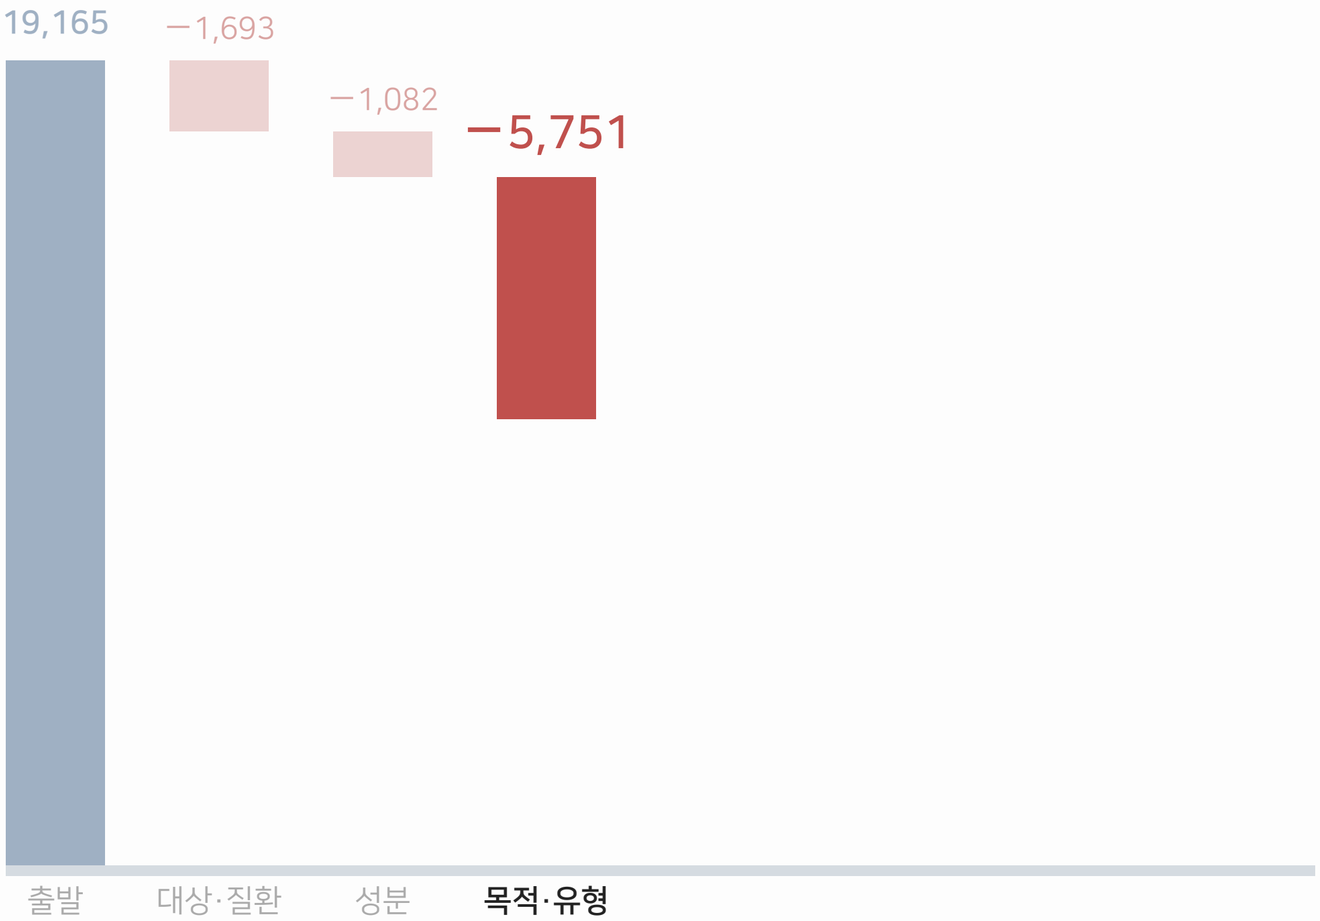
17,472 → 필터링 후 16,390

제품명과 실제 성분이 다른 제품 제외

홍삼·천마 등에 영양소만 더한 제품 제외

목적 · 유형

영양제 필터링 4 / 9



필터링 전

16,390 → 필터링 후 10,639

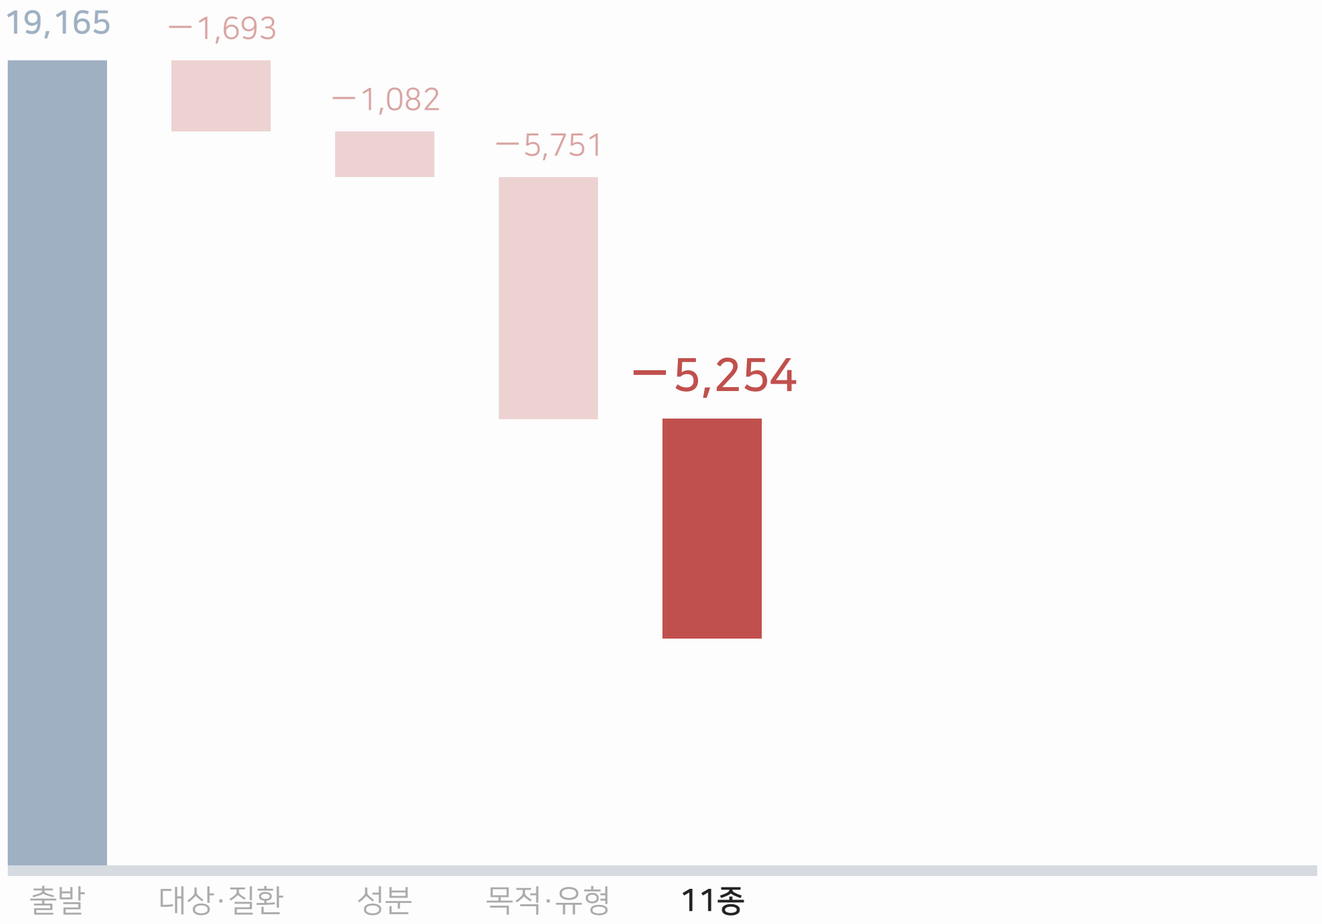
다른 목적(다이어트·관절 등) 섞인 제품 제외

단일 / 목적형 / 종합비타민으로 나누기

어느 유형에도 맞지 않으면 제외

영양제 11종

영양제 필터링 5 / 9



필터링 전

10,639 → 필터링 후 5,385

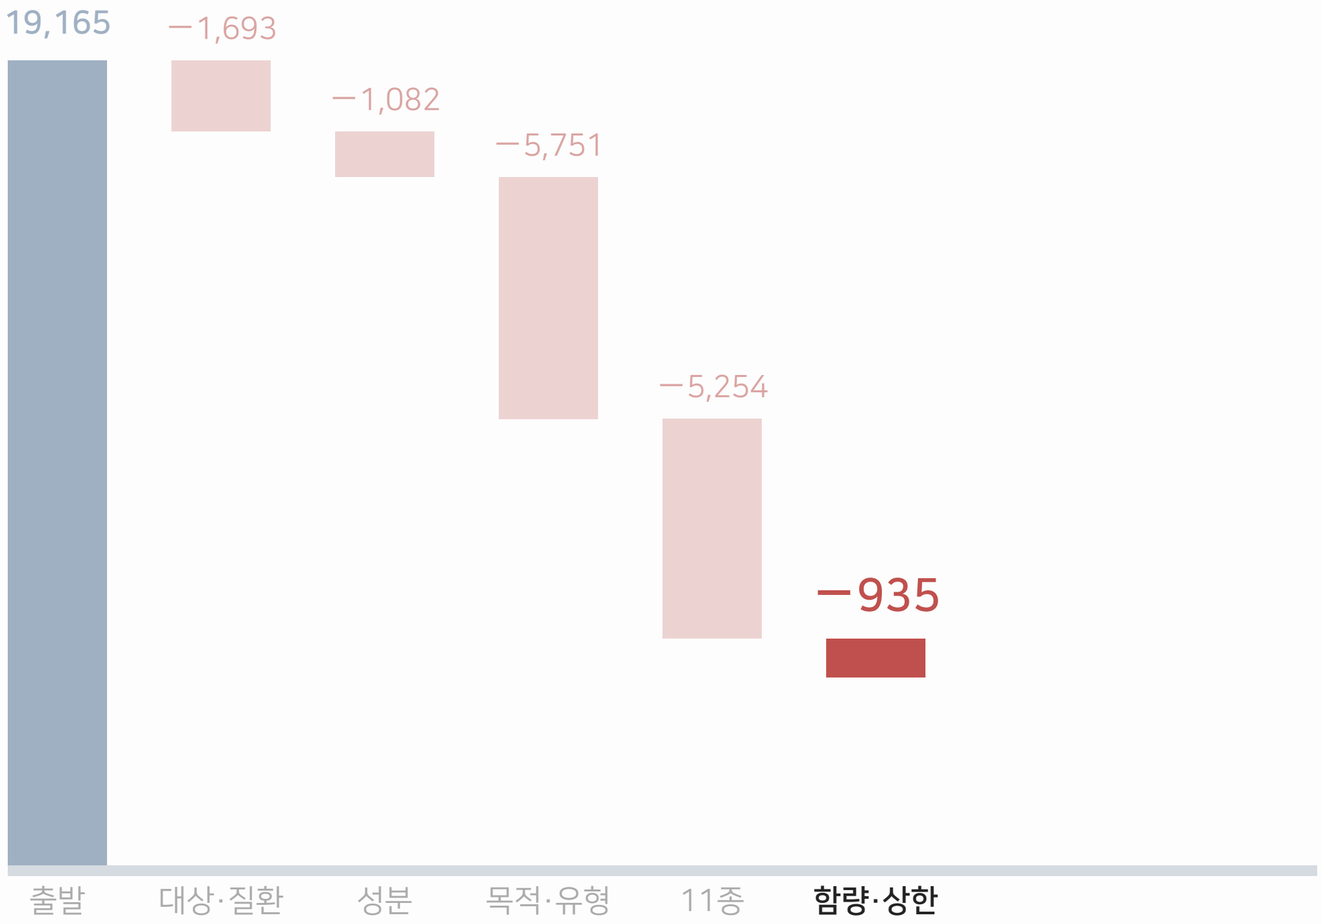
영양제 11종으로 묶기

11종 밖 제품 제외

유산균·오메가3 등은 생활기능 영양제로 따로

하루 함량 · 상한섭취량

영양제 필터링 6,7 / 9



필터링 전

5,385

→

필터링 후

4,450

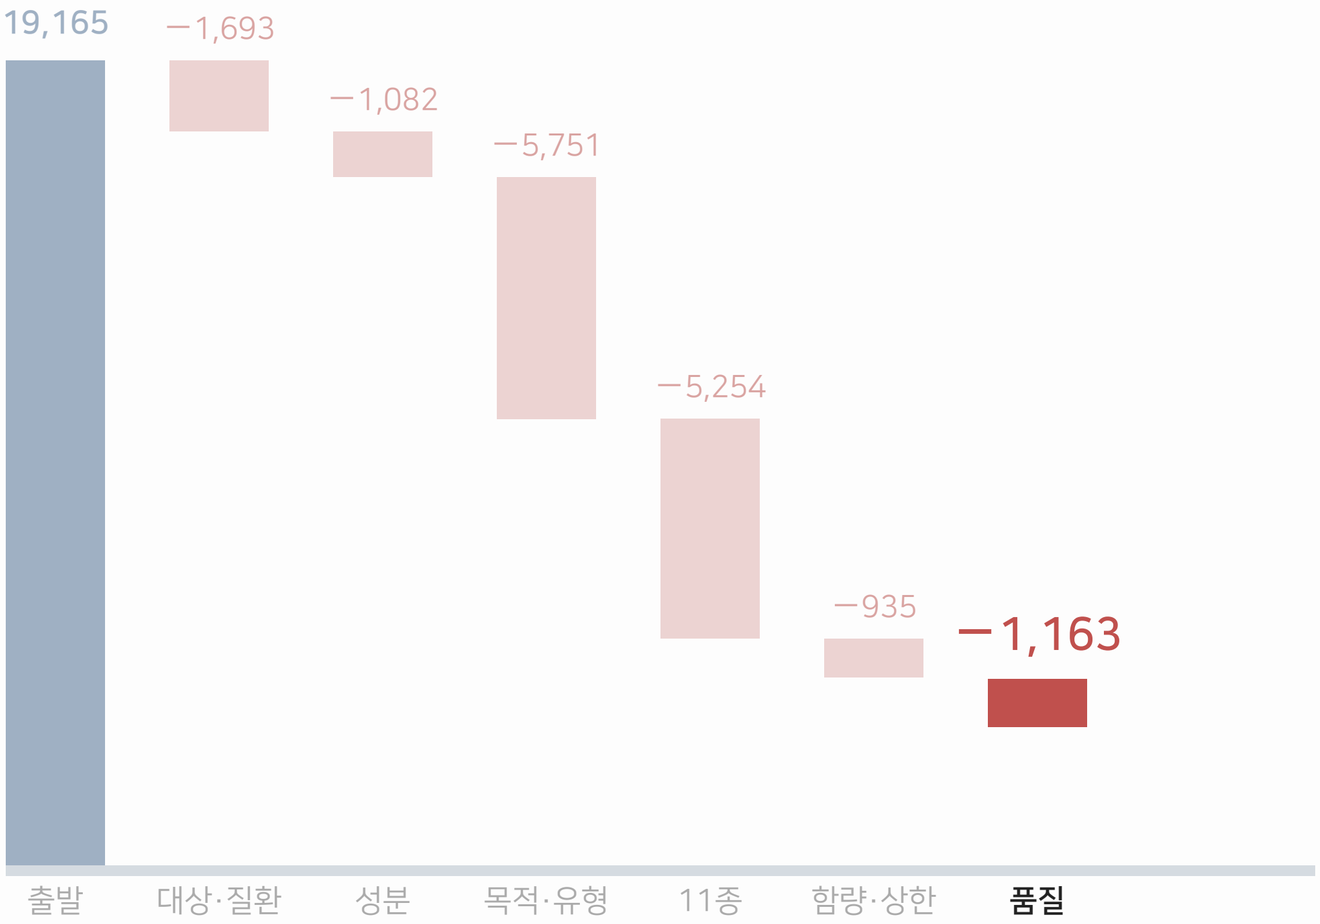
하루 섭취량 기준으로 함량 계산

2025 KDRI 상한섭취량 초과 → 제외

함량을 확인할 수 없음 → 제외

정보·제품 구성 기준 적용

영양제 필터링 8 / 9



필터링 전

4,450

→

필터링 후

3,287

주의사항이 없는 제품

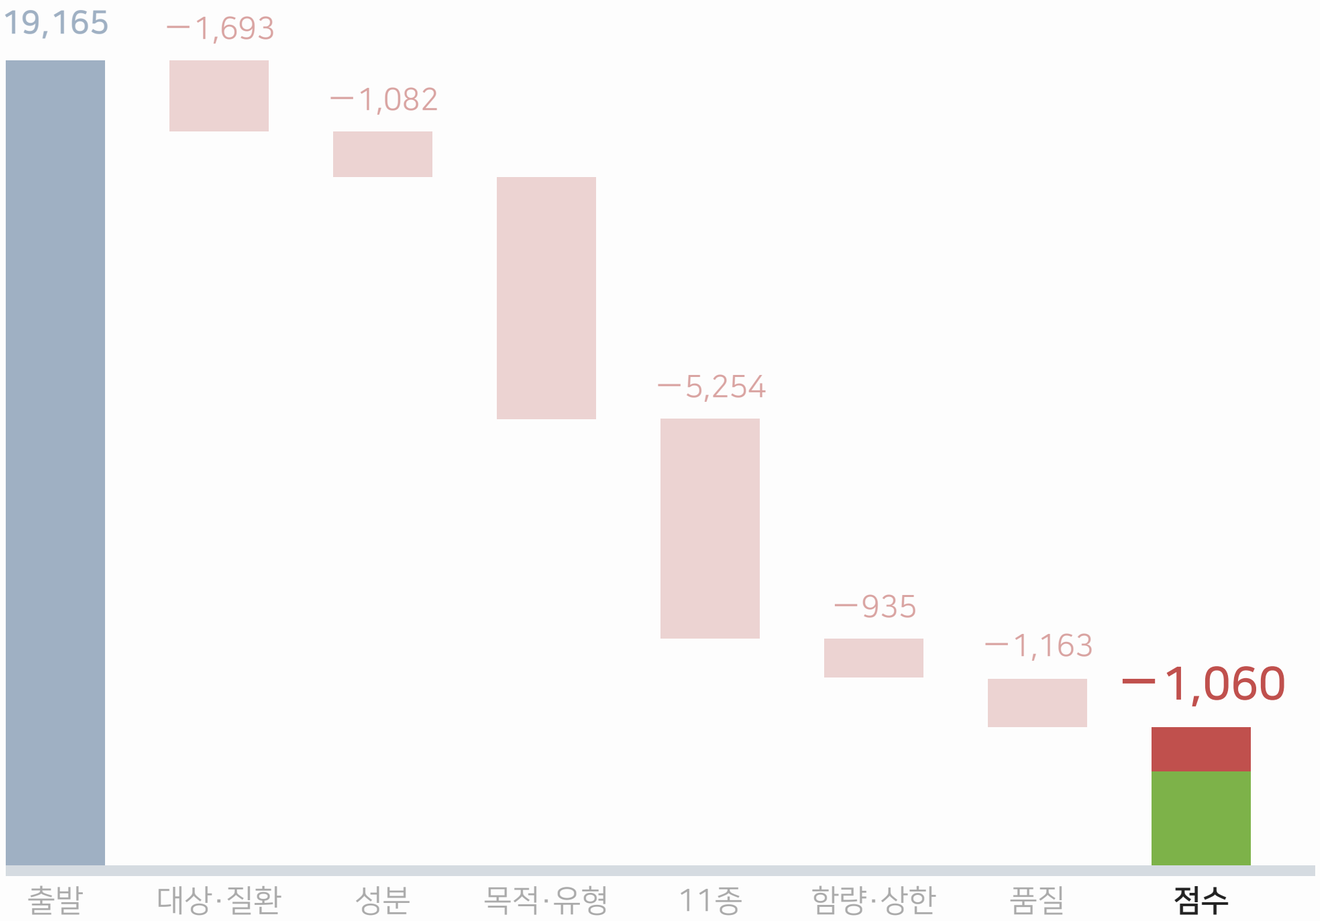
권장량 500% 초과

원재료 30개 초과

비슷한 제품은 최근 신고만

프로젝트 선정 기준을 충족한 최종 후보

영양제 필터링 9 / 9



필터링 전 → 필터링 후

3,287 → 2,227

프로젝트 내부 후보 선정 기준 : 70점 이상
제품의 효과나 우열을 평가한 점수는 아님

함량 적정성	40점
섭취 편의	20점
원료 단순성	20점
주의 원료	10점
성분 구성	10점

상한에 가까우면 −5 / −10 감점 · 종합비타민은 3개 항목으로 환산

출발

생활기능 영양제 필터링 1 / 4



출발 제품 수

4,577

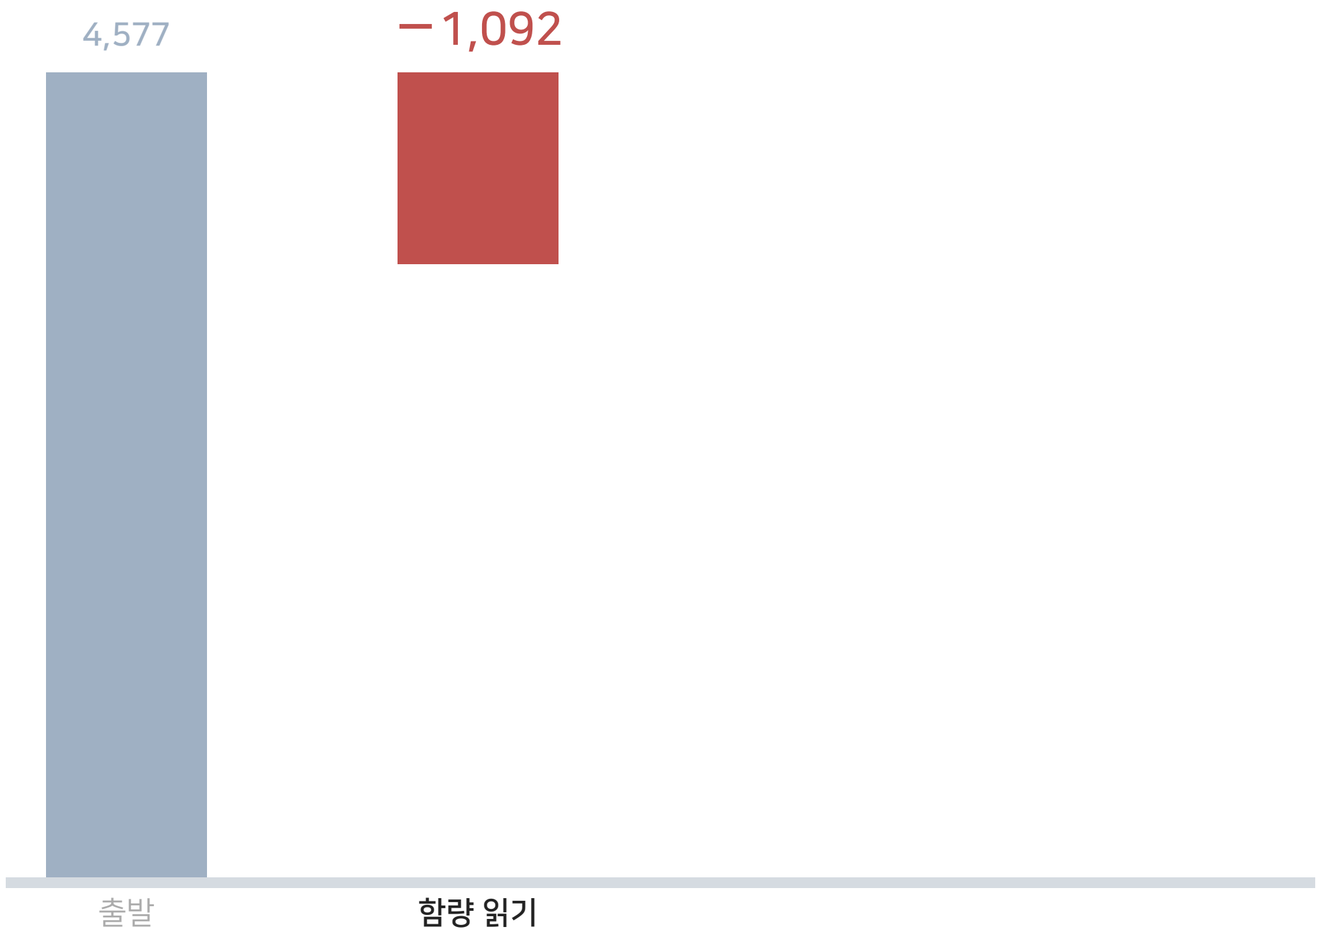
유산균 · 오메가3 · 루테인 · 밀크씨슬

주 목적이 이 4가지인 제품

일반 대상만 · 영양제와 겹치는 제품 없음

하루 함량 읽기

생활기능 영양제 필터링 2 / 4



필터링 전

4,577

→

필터링 후

3,485

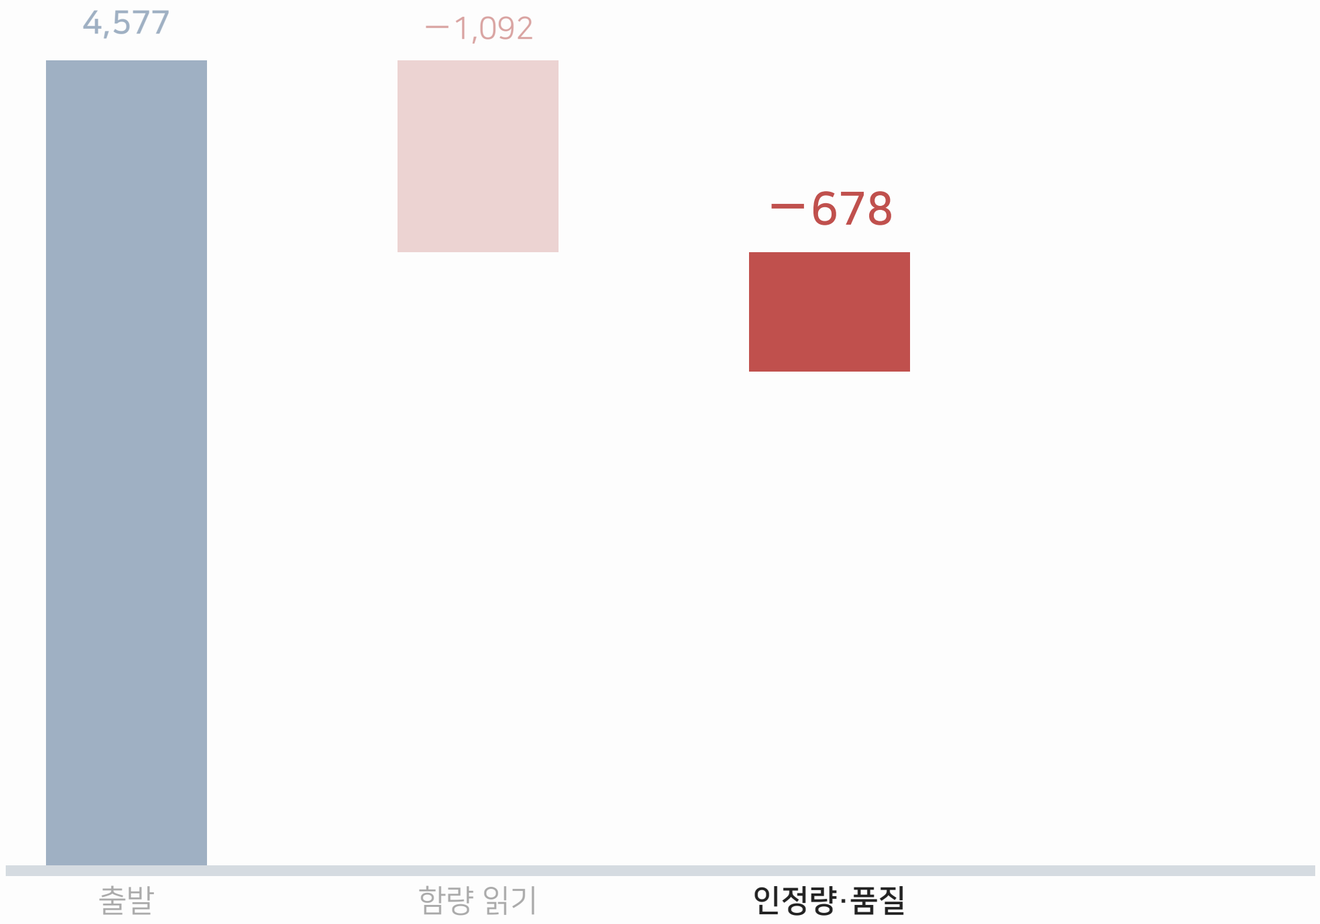
원료용 제품 제외 (소비자 제품 아님)

섭취방법·하루 섭취량을 읽지 못함

주성분 함량 확인 불가

섭취량 및 제품 구성 기준 확인

생활기능 영양제 필터링 3 / 4



필터링 전

3,485 → 필터링 후 2,807

식약처·공인 기준

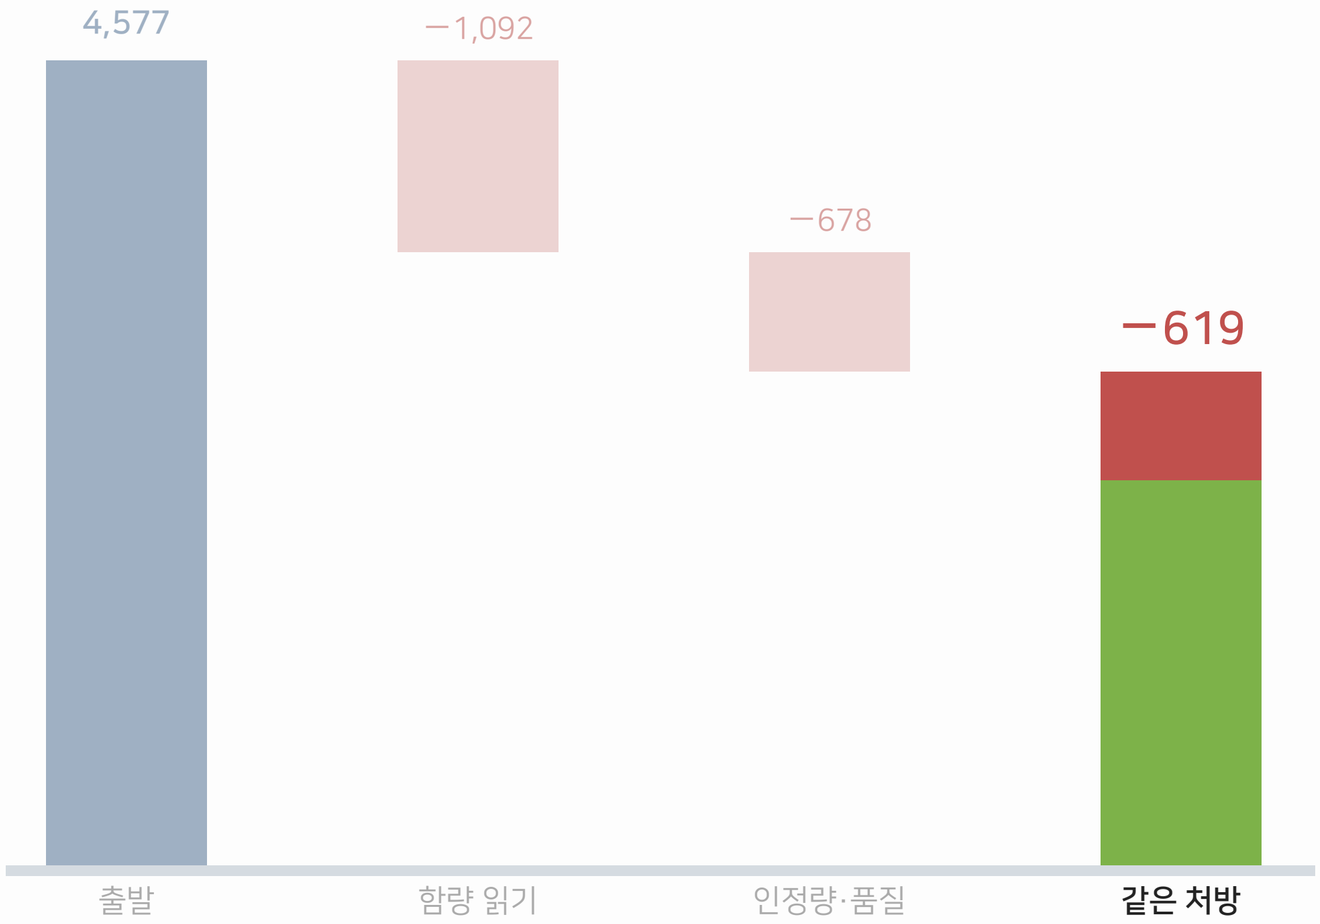
- 식약처 인정 섭취량 범위 밖 · KDRI 상한 초과

팀이 정한 기준

- 함께 든 성분 5개 이상
- 하루 3개 이상 먹어야 함
- 함께 든 비타민·미네랄 상한 50% 이상
- 주의사항 없음 · 원재료 30개 초과
- 비슷한 제품은 최근 신고만

동일 구성 제품의 중복 정리 → 최종 후보

생활기능 영양제 필터링 4 / 4



필터링 전

2,807

→

필터링 후

2,188

업체·원료·함량·제형이 같은 제품은 가장 최근 신고 제품만 유지

유산균	964
오메가3	523
루테인	394
밀크씨슬	307

점수는 쓰지 않음 (기능성 원료는 1일 기준치가 없음)

06

웹 서비스 구현

웹 서비스를 구현한 이유

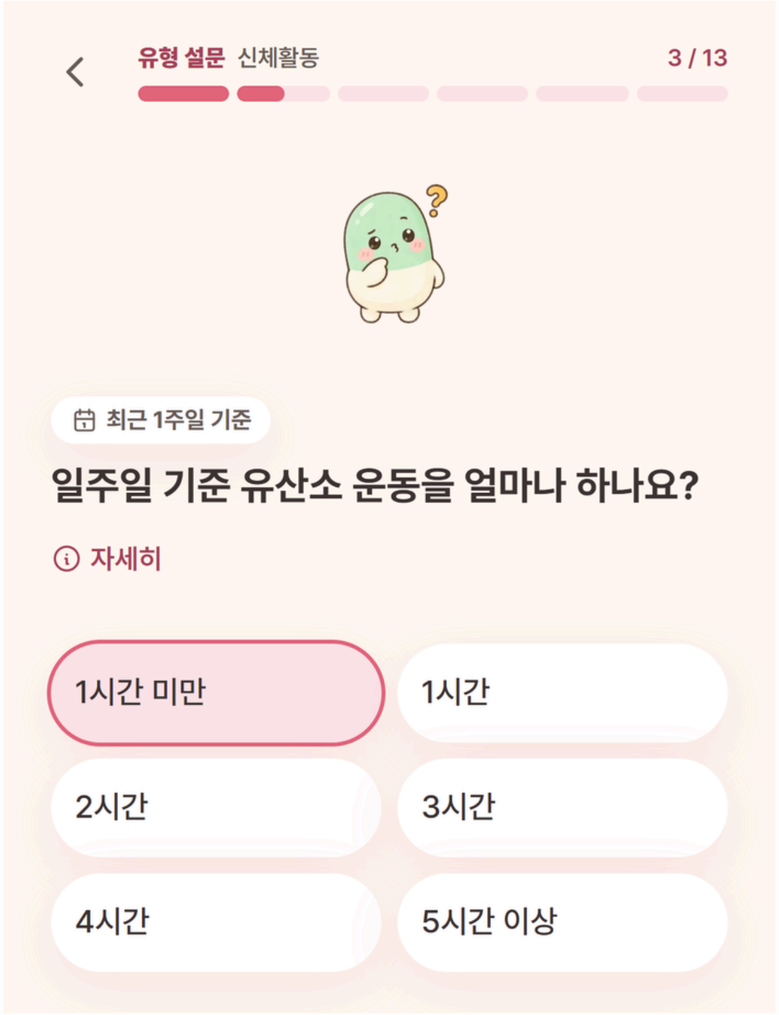
머신러닝 분석 결과를



참여형으로 쉽고 재밌게



서비스 한눈에 보기: ① 유형 설문





서비스 한눈에 보기: ② 유형 결과

나의 NBTI 유형은



예민보스

쉬고 싶은 예민보스

스트레스를 많이 느끼고 운동할 틈이 적은 편이에요.

#스트레스많음 #운동부족 #끼니패스

같은 유형의 섭취 경향



철을 적게 먹어요

10명 중 5명



마그네슘을 적게 먹어요

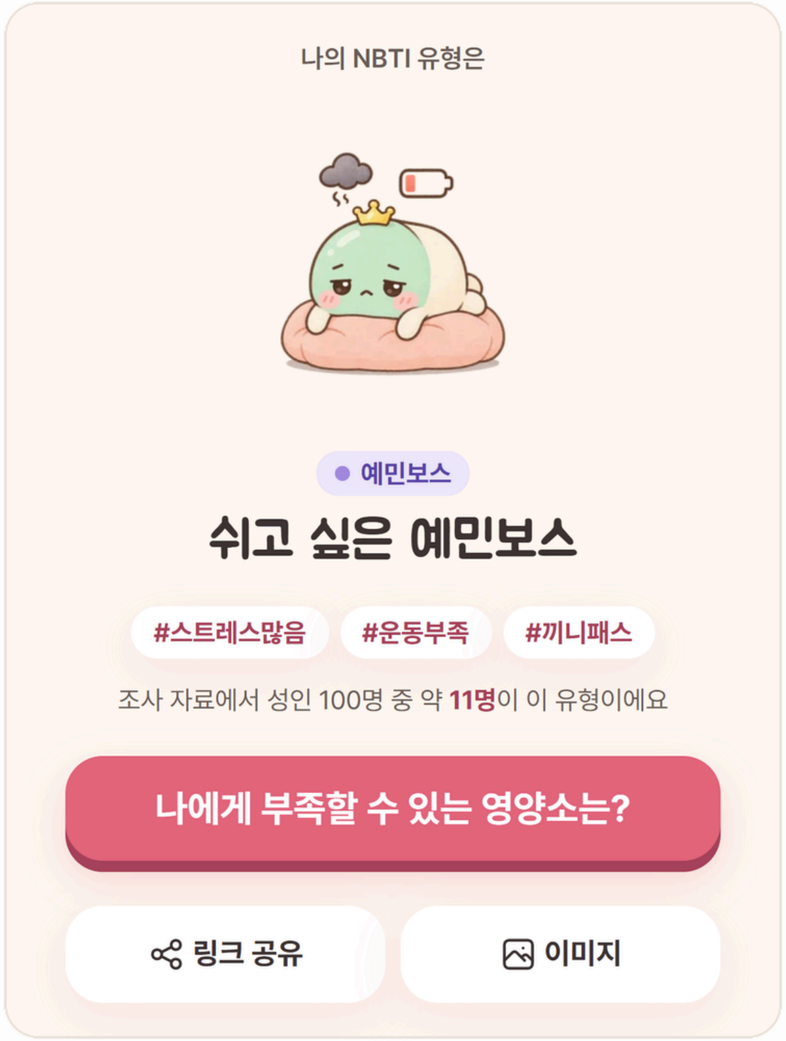
10명 중 6명

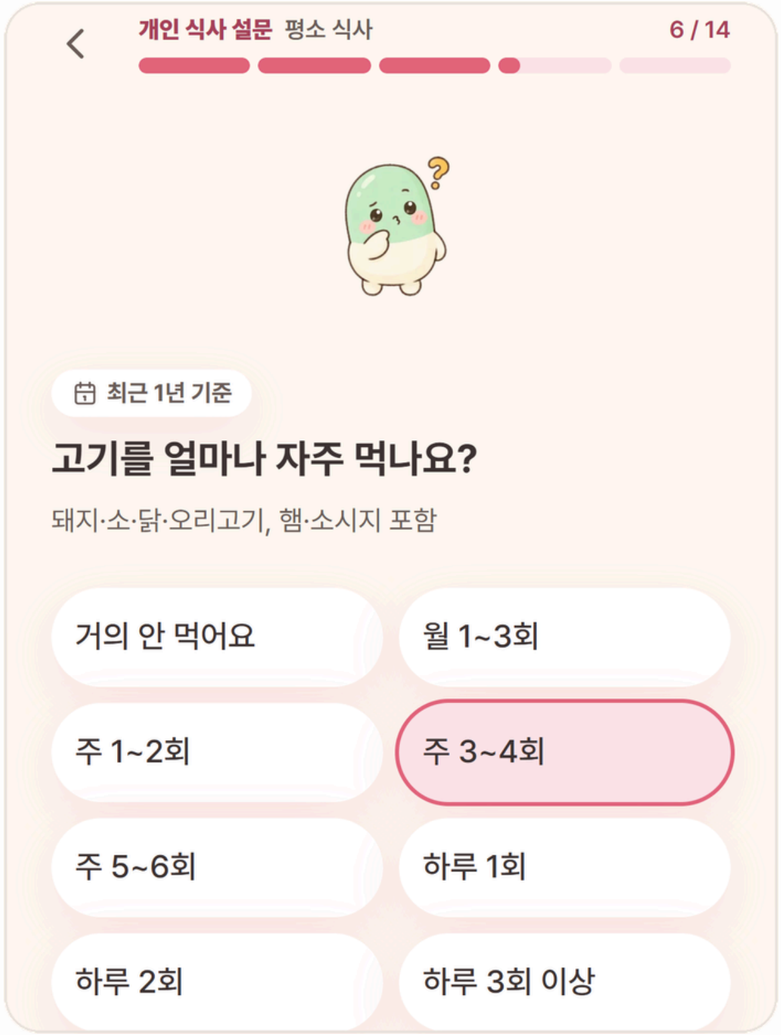


비타민 B1을 적게 먹어요

10명 중 5명

서비스 한눈에 보기: ③ 식습관 설문





서비스 한눈에 보기: ④ 나의 결과





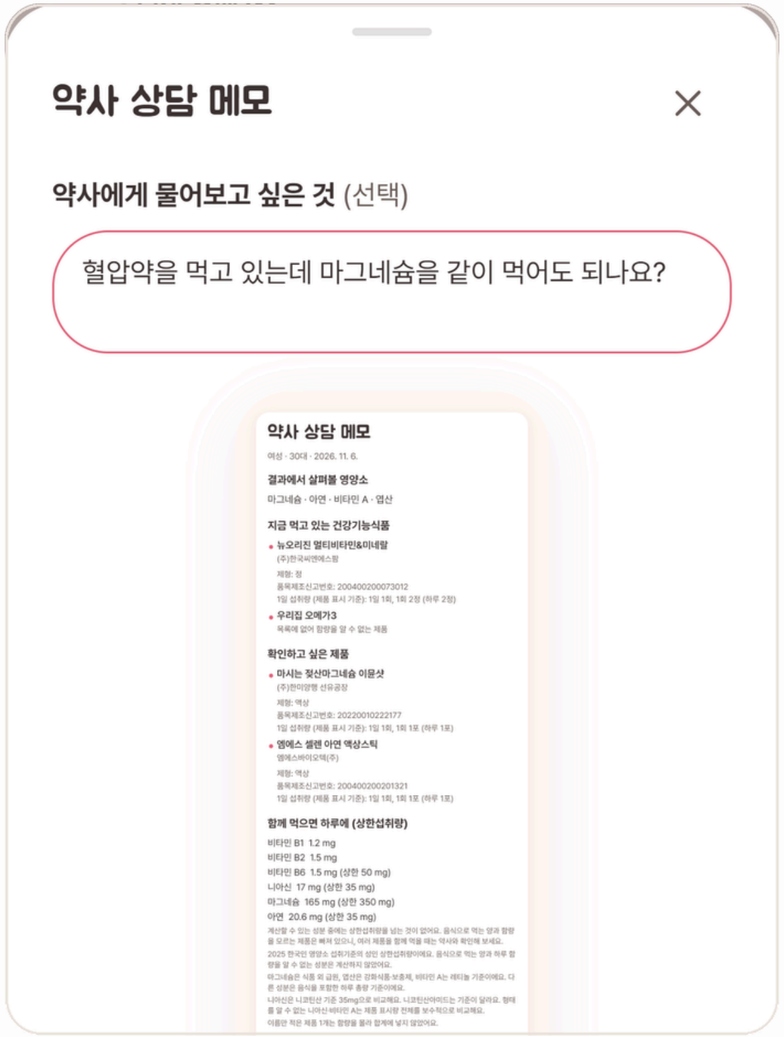


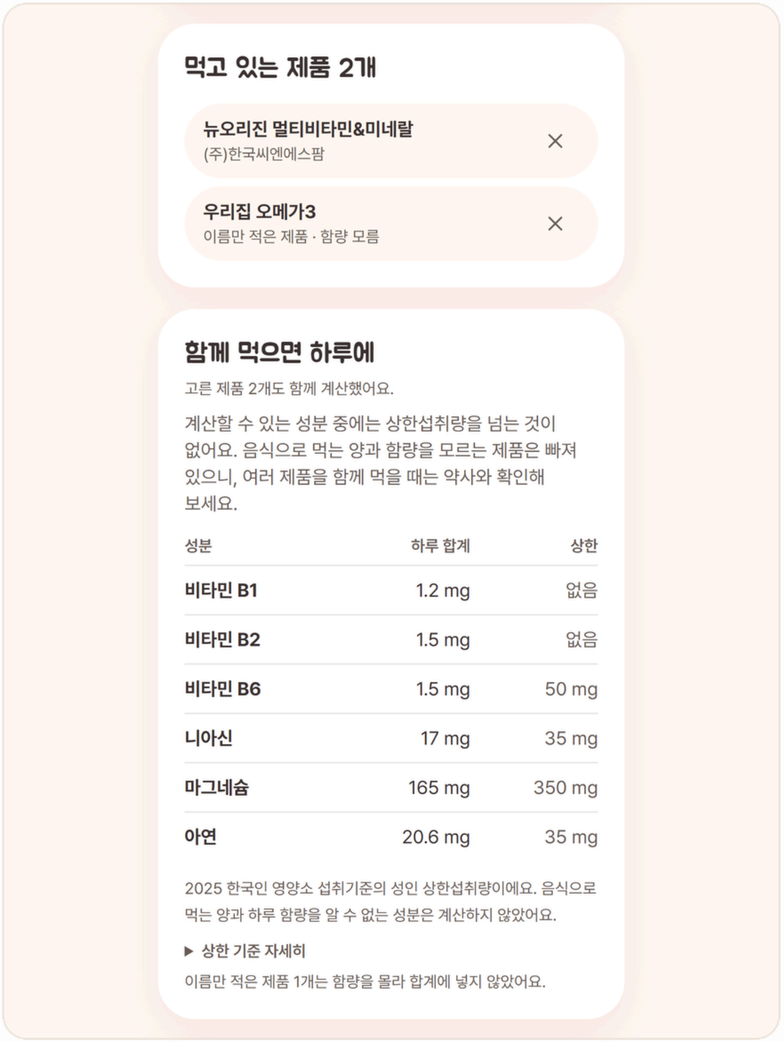
서비스 한눈에 보기: 영양제 둘러보기





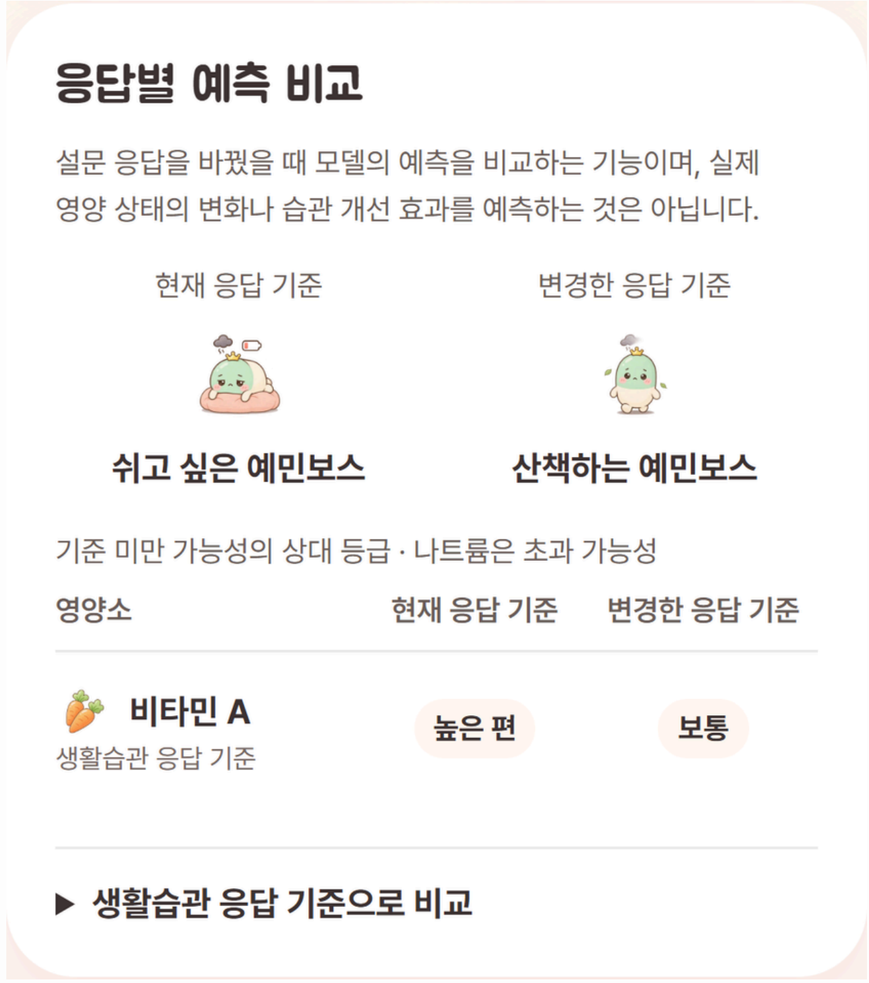
서비스 한눈에 보기: 전문가 상담을 위한 정보 정리





서비스 한눈에 보기: 응답 변경에 따른 예측 결과 비교





07

시연



Team 머신 2러닝

NBTI 유형 검사

Nutrient + MBTI

생활습관으로 알아보는 나의 영양 유형

08

의의 및 한계

기존 서비스와의 접근 차이

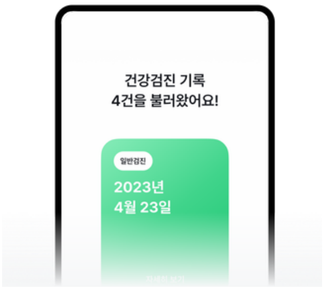
생활습관 설문으로 가볍게 시작하는 나의 영양 관리

필라이즈



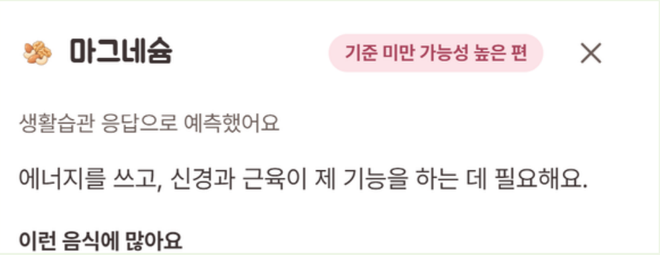
기록과 건강 데이터 기반 통합 관리

알고케어



건강 데이터 기반 맞춤 영양제

본 프로젝트



생활습관에서 시작하는 영양 점검

본 프로젝트의 의의

설문 기반 영양 예측과 개인별 관리 정보 제공



간단한 설문 기반 점검

건강관리의 시작점 제공



유형과 개인의 차이 구분

집단 설명과 개인 예측의 보완



결과와 관리 정보 연결

확인에서 정보 탐색까지 연결

한계 및 향후 과제

자료의 제약과 예측 범위를 고려한 추가 검증 필요

	현재 한계	향후 과제
자료의 제약	하루 섭취 기록의 변동성 과거 FFQ 자료와 적용 연령의 제한	반복 식사 기록과 최근 자료로 추가 검증
예측의 범위	영양소별 예측력 차이 실제 결핍·필요 복용량 판단의 한계	영양소별 성능·확률 보정 점검 외부 자료를 통한 검증
서비스 효과	실제 습관·영양 상태의 개선 효과는 미검증	사용성 평가와 이용 전후 변화 추적

Q&A
감사합니다.



참고자료

각 기법은 서로 다른 질문에 답합니다

PCA는 정보 요약, 군집화는 유형 구분, 분류 모델은 정답 예측에 사용

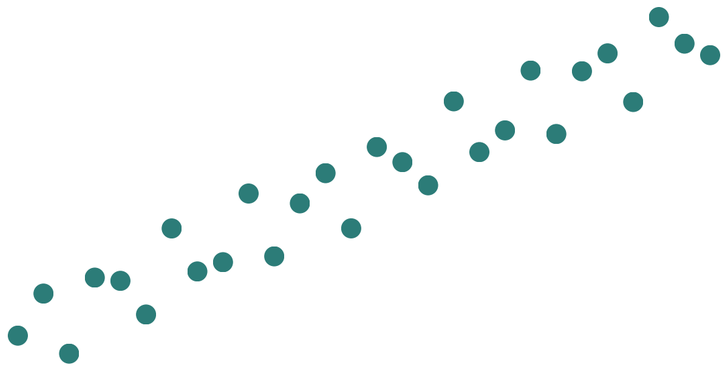
단계	질문	학습에 정답 y 사용
PCA	변수 정보를 적은 수의 축으로 요약할까?	사용하지 않음
K-means / K-medoids	비슷한 생활패턴끼리 어떻게 묶을까?	사용하지 않음
Logistic / HistGradientBoosting	이 응답에서 기준 미만·초과 가능성은?	영양소별 0/1 정답 사용
음식·제품 연결 규칙	어떤 관리 정보를 연결할까?	별도 예측 모델 아님

생활습관 유형화와 개인 영양 예측은 목적과 평가 기준이 다릅니다.

PCA · 주성분분석

데이터가 많이 퍼진 방향부터, 서로 직교하는 새 축을 만듭니다

PC1: 분산이 큰 방향



개념도 · 합성 자료

프로젝트 적용

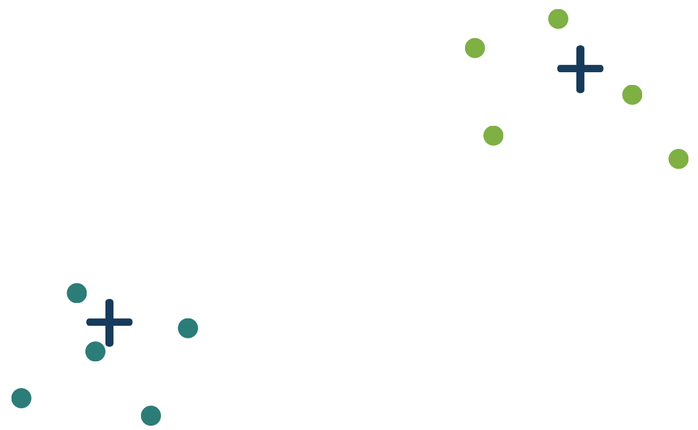
생활습관 7개 변수
표준화 후 PCA 5차원
이 공간에서 대분류 군집화

변수를 2개 버리는 것과 다름
각 주성분은 여러 변수의 가중합

“왜 5차원인가?”에는 누적 설명분산과 대안 설정 비교로 답해야 합니다.

K-means · 평균 중심으로 군집화

군집 안의 제곱거리 합이 작아지도록 배정과 중심 갱신을 반복



\+ = 평균 중심

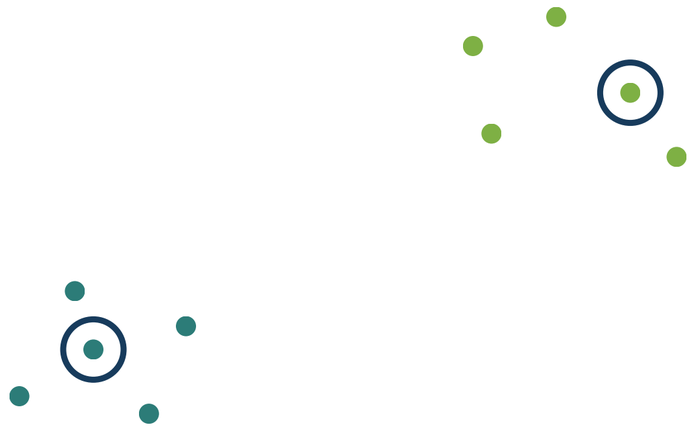
반복하는 작업

① 초기 중심 K개 설정
② 가장 가까운 중심에 점 배정
③ 각 군집 평균으로 중심 갱신
④ 변화가 작아질 때까지 반복

장점: 계산 효율이 좋음　**주의: 평균 중심과 이상치 민감도**

K-medoids · 실제 관측치를 대표점으로

각 군집에서 다른 점들과의 거리 합이 작은 관측치를 대표로 선택



동그라미 = 선택된 실제 관측치

반복하는 작업

① 대표 관측치 K개 설정
② 가장 가까운 대표점에 배정
③ 비용을 줄이는 대표점 탐색
④ 대표점 교체와 배정 반복

프로젝트의 선택 이유는 이론적 장점에 실제 비교 결과를 더해 설명합니다.

K-means와 K-medoids의 차이

중심의 정의와 목적함수가 달라, 같은 데이터도 다른 구분이 나올 수 있음

비교 항목	K-means	K-medoids
중심	평균 벡터	실제 관측치
최소화 대상	중심까지 제곱거리 합	대표점까지 거리 합
거리 사용	유클리드 제곱거리 기반	선택한 거리 척도 사용 가능
이상치 영향	평균 중심이 끌릴 수 있음	상대적으로 덜 민감할 수 있음
계산 비용	대규모 자료에서 효율적	일반적으로 더 큰 비용
공통 주의점	K·초기값·척도·거리 선택에 영향	군집의 타당성을 별도로 검증

현재 본문: PCA 5차원 + K-medoids K=4 · 세부유형은 대분류별 K=3

η^2 · 이 변수에서 군집별 차이가 얼마나 뚜렷한가?

군집을 나눈 뒤, 특정 변수의 값이 군집마다 얼마나 다른지 보는 지표입니다.

예시 변수: 주당 근력운동 일수

η^2가 높은 경우

군집마다 운동 일수가 다름

군집	평균 근력운동
A	주 0일
B	주 2일
C	주 5일

같은 군집 안의 값도 각 평균 주변에 모여 있음

η^2가 낮은 경우

세 군집의 평균과 분포가 비슷함

군집	평균 근력운동
A	주 2일
B	주 2일
C	주 2일

각 군집 안에는 주 0~4일인 사람이 섞여 있음

알고리즘이 준 “변수 중요도”가 아니라, 최종 군집에서 관찰되는 차이입니다.

설명용 가상 예시 · η^2는 0~1의 값 · 입력에서 제외한 변수도 군집 간 차이를 계산할 수 있음

흡연과 음주는 중요한데 왜 제외했나요?

군집이 흡연·음주 중심으로 갈리는 편중을 줄여,
운동·수면·식사 패턴의 차이도 드러내기 위해 제외했습니다.

답변 근거

변수군 평균 η^2	기존 군집	변경 후 군집
흡연·음주 5개	0.731	0.027
그 외 생활습관 9개	0.066	0.228

최종 군집 입력: 흡연·음주 5개 제외 + 세 끼 빈도 3개를 1개로 통합 = 7개

군집화 입력에서만 제외했습니다. 개인 생활습관 예측 모델에는 흡연·음주를 사용합니다.

군집 수와 군집의 타당성은 어떻게 보나요?

분리도·재현성·규모·활용 가능성을 함께 검토합니다

관점	지표·확인 방법	답하는 질문
분리도	실루엣: 군집 내 거리와 군집 간 거리	서로 얼마나 떨어져 있나?
안정성	재표집·시드 반복의 ARI 등	다시 실행해도 비슷한가?
규모	최소 군집 비율·군집 불균형	너무 작은 집단은 없는가?
해석·활용	변수 프로필·안내 차이	생활습관 설명에 쓸 수 있나?

우리의 유형은 연속적인 생활패턴을 설명하기 위한 구분으로 해석합니다.

Logistic Regression · 가중합을 확률로

학습된 계수와 절편으로 점수를 만든 뒤 sigmoid로 변환

설문 응답

성별·나이
생활습관 또는 식품빈도

가중합 점수

$z = b + \Sigma\, w_j x_j$
계수·절편은 학습

확률 변환

$p = 1 / (1 + e^{-z})$
0과 1 사이의 값

예시: z=0이면 p=0.5, z가 커지면 p가 증가

최종 적용: 생활습관 비타민 C 1개 + 평소 식사 모델 10개

Gradient Boosting · 남은 오차를 순차 보완

앞선 모델의 손실을 줄이는 방향으로 나무를 하나씩 더합니다

초기 점수

전체 경향에서
예측 시작

나무 1

현재 손실을 줄이는
보정값 학습

나무 2…

남은 손실을 줄이는
보정값 추가

확률

원점수 합산 후
sigmoid 변환

$$F_m(x) = F_{m-1}(x) + \text{학습률} \times \text{나무의 보정값}$$

비선형 관계·변수 조합을 표현할 수 있지만, 깊이·학습률 등의 조절이 필요합니다.

Histogram 기반은 무엇이 다른가요?

연속값을 구간으로 묶어 분기 후보를 탐색하는 부스팅 구현

구분	설명
Gradient Boosting	나무를 순차적으로 더해 손실을 줄이는 학습 방식
Histogram	수치값을 구간화해 분기 후보 계산을 효율화하는 방법
우리 구현	scikit-learn HistGradientBoostingClassifier
XGBoost와의 관계	같은 부스팅 계열이지만 별도 라이브러리·구현
최종 사용	개인 생활습관 모델 13개 / 유형 프로필 철 모델 1개

발표 표기: Histogram-based Gradient Boosting 또는 HistGradientBoosting

비교 실험에 등장한 기법의 의미

검토한 방법과 최종 채택 모델을 구분해서 답합니다

ExtraTrees

무작위 분기를 활용한 여러 나무
나무별 예측을 모아 결과 계산
부스팅의 순차 보완과 구분

지식증류

교사 모델의 예측 정보 활용
학생 모델이 이를 학습
입력 정보의 한계를 없애지는 못함

개발 중 비교했지만, 최종 저장 모델은 로지스틱과 HistGradientBoosting으로 구성

교사·학생 구성과 세부 설정은 원코드 확인 후 설명 · 성능 향상을 보장하는 기법은 아님

AUC·PR AUC·Brier는 무엇을 보나요?

구분 성능과 확률 오차를 함께 확인합니다

지표	무엇을 확인하나?	해석 주의
ROC AUC ↑	기준 미만·초과 사례의 순위 구분	정확도와 다름
PR AUC ↑	관심 사례를 찾는 정밀도·재현율	양성률·계산 방식 확인
Brier ↓	예측확률과 0/1 정답의 평균 제곱오차	보정 성능만 단독 측정하는 값 아님
확률 보정	예측 0.7 집단의 실제 비율이 약 0.7인가?	보정 곡선·기준 예측과 함께 평가

평균 지표와 영양소별 지표를 함께 제시 · 확률이 높다고 결핍을 진단하지 않음

생활습관 변수

유산소 운동	0 ,1
근력 운동	일/주
좌식 시간	분/일
수면 시간	시간/일
스트레스 인지	0, 1
아침식사 빈도	0~3
점심식사 빈도	0~3

저녁식사 빈도	0~3
외식 빈도	0~6
흡연 여부	0, 1
하루 흡연량	개비
음주 여부(월)	0, 1
음주 빈도	0~5
1회 음주량	0~5

과거 데이터로 현재 사용자를 예측해도 되나요?

같은 한국 성인 집단의 관계를 활용해 적용을 시도할 근거가 있습니다.
다만 현재 사용자에서의 성능은 추가 검증이 필요합니다.

적용을 시도한 근거

공통된 대상 집단

같은 국민건강영양조사의
한국 성인 자료에서 관계를 학습

성별·나이를 입력해 개인별 차이를 반영

검증한 범위

모델의 연도 분리

2012~2015년 학습 / 2016년 평가
2022~2023년 학습 / 2024년 평가

과거의 다른 표본에서 성능 확인
현재 사용자에 대한 검증은 남아 있음

성별·연령을 고려해도, 같은 나이·성별의 식생활이 시대에 따라 바뀌는 영향은 남습니다.

FFQ 모델 적용 범위: 19~64세 · 섭취기준 미만·초과 가능성 점검 · 최근 자료로 재검증 필요

왜 어떤 영양소는 EAR, 어떤 영양소는 AI인가요?

영양소마다 필요량을 추정할 연구 근거가 달라,
2025 한국인 영양소 섭취기준에 설정된 EAR 또는 AI로 비교했습니다.

구분	EAR · 평균필요량	AI · 충분섭취량
의미·설정 배경	필요량 근거가 충분할 때 설정 건강한 집단 약 50%의 필요량 충족	EAR 산출 근거가 부족할 때 설정 건강한 집단의 섭취량 등을 참고
영양소 예시	단백질·칼슘·철·비타민 A·C 등	식이섬유·칼륨·비타민 D·E
미만일 때	평균필요량보다 적게 섭취	미만만으로 부족 여부 판단 불가

AI 미만은 참고용 점검 지표입니다. EAR 미만과 같은 의미의 “영양 부족률”로 해석하지 않습니다.

24시간 회상 자료는 학습에 어떻게 활용했나요?

생활습관으로 영양소 섭취 상태를 예측하도록,
24시간 회상 자료에서 학습 정답을 만들었습니다.

같은 참여자의 생활습관 응답과 섭취 자료를 연결해 학습

입력 X

생활습관 설문 응답

성별·나이와 생활습관

+

정답 y

하루 섭취량의
기준 미만·초과 여부

24시간 회상 섭취량을 기준과 비교

→

예측 모델 학습

생활습관 응답과
섭취 기준 판정의
관계를 학습

해석할 때의 한계

정답이 하루 섭취량을 바탕으로 하므로, 평소의 지속적인 과부족으로 해석하는 데 한계가 있습니다.

AUC가 약 0.66인데, 사용할 만한가요?

구분 성능에는 한계가 있어,
식생활 점검을 돕는 참고 정보로 활용했습니다.

생활습관 모델의 평가 결과

0.664

14개 영양소 평균 ROC AUC

2022~2023년 학습 / 2024년 평가

AUC 0.664는 정확도 66.4%라는 뜻이 아님

어디까지 말할 수 있나요?

설문 응답과 섭취 기준 판정의 관련성을 일부 포착

개인의 부족을 확정하기에는 성능이 제한적
관심을 두고 살펴볼 영양 항목을 안내

평균값만으로 모든 영양소가
같은 수준의 성능을 보인다고 할 수 없음

실제 활용성은 판정 기준별 성능과 사용자 평가로 추가 확인해야 합니다.

평가 대상은 조사된 하루 섭취량의 기준 미만·초과 여부

이 프로젝트로 어디까지 말할 수 있나요?

생활습관·식품빈도 응답을 영양 점검과 관리 정보 탐색으로 연결

설명 가능한 내용	현재 검증 범위를 넘어서는 표현
유형별 관찰된 섭취 경향을 설명	유형만으로 개인의 결핍을 확정
개인 응답의 기준 미만·초과 가능성 추정	혈액검사 결과·질환·필요 복용량을 예측
음식·습관·제품 정보의 탐색을 지원	서비스 사용으로 실제 영양 상태가 개선됨
전통적 머신러닝으로 구현	딥러닝보다 우수함을 입증
생활습관에서 가볍게 시작하는 설계	기존 서비스는 생활습관 설문을 쓰지 않음

다음 검증: 최근 외부 자료 · 반복 식사 기록 · 사용자 평가 · 이용 전후 변화