생활습관 군집 귀무검정 결론 보고서

Nov 4, 2026 · @지연

결론

대분류 4개와 12유형 모두 판정은 **"연속 분포를 나눈 구분"**입니다. 실제 실루엣이 덩어리 없는 가짜 자료의 최댓값을 넘지 못했습니다.

- **말할 수 있는 것:** 간격 4 SD 이상의 강한 덩어리는 없어 보입니다. 이 간격에서는 시험한 모든 경우에 검정이 실루엣으로 덩어리를 잡아냈습니다.
- **말할 수 없는 것:** "덩어리가 전혀 없다." 간격 2 SD 이하는 한 번도 검출하지 못했습니다.
- **쓰면 안 되는 것:** 세부 실루엣 0.514~0.859를 분리가 잘 된 근거로 드는 것. 가짜 자료에서도 비슷하게 나오고, 덩어리를 심어도 검출하지 못했습니다.

이 결과는 12유형이 쓸모없다는 뜻이 아닙니다. 유형의 가치는 안정성(ARI 0.945)과 영양소 예측 개선(15개 중 13개)으로 설명해야 합니다. 이 두 수치는 이번에 다시 계산하지 않고 기존 팀 문서에서 가져왔습니다.

검정 방법

실제 자료 15,062명에 쓴 지연님 코드(`kmedoids_final.py`)를 가짜 자료에도 그대로 적용해 실루엣을 비교했습니다. 세분화 변수는 실제 자료에서 고른 조합을 고정해서 썼습니다.

자료	만드는 법	횟수	확인하는 것
무작위 A	7변수를 각각 따로 섞음	20회	변수 관계가 없어도 나오는 실루엣
무작위 B	변수별 분포와 순위상관을 유지해 새로 생성	20회	상관관계만 있어도 나오는 실루엣
덩어리 심은 자료	변수별 분포는 실제와 같게 두고 덩어리 간격을 조절	간격 6단계, 각 5회	진짜 덩어리를 잡아내는 능력

판정 기준은 실행 전에 정했습니다. 실제 값이 A·B 20회 최댓값을 모두 넘으면 "뚜렷한 구조", A만 넘으면 "변수 관계에서 오는 구조", 둘 다 못 넘으면 "연속 분포를 나눈 구분"입니다.

결과

실제 값은 네 지표 모두 가짜 자료 A·B의 범위 안이거나 그보다 낮습니다. 괄호 안은 20회 범위입니다.

지표	실제	무작위 A 평균	무작위 B 평균
대분류 실루엣 (PCA 5차원)	0.163	0.183 (0.155~0.222)	0.207 (0.186~0.216)
12유형 실루엣 (7변수, 주 지표)	0.100	0.096 (0.043~0.140)	0.117 (0.103~0.130)
12유형 실루엣 (PCA 5차원)	0.080	0.077 (0.027~0.105)	0.084 (0.058~0.110)
세부 실루엣 가중평균	0.627	0.626 (0.588~0.687)	0.625 (0.611~0.646)

검정력은 덩어리를 심은 자료로 확인했습니다. 간격 4 SD부터는 대분류와 12유형 모두 매번 검출했고, 세부 실루엣은 간격과 상관없이 한 번도 검출하지 못했습니다.

덩어리 간격 (SD)	대분류: 4덩어리 자료	대분류: 12덩어리 자료	12유형	세부	12유형 실루엣 평균	12유형 복원 (ARI)
0	0/5	0/5	0/5	0/5	0.099	0.00
1	0/5	0/5	0/5	0/5	0.103	0.03
2	0/5	0/5	0/5	0/5	0.115	0.13
3	1/5	5/5	1/5	0/5	0.138	0.28
4	5/5	5/5	5/5	0/5	0.161	0.43
6	5/5	5/5	5/5	0/5	0.222	0.66

검출 기준은 가짜 자료 40회의 최댓값입니다. 대분류 0.222, 12유형 0.140, 세부 0.687을 넘으면 검출로 봤습니다.

간격 3 SD는 구조에 따라 결과가 갈립니다. 12유형은 평균 0.138로 기준 바로 아래였습니다.

미리 정한 "복원(ARI 0.8 이상)되는 간격에서 5회 모두 검출" 기준은 대분류의 12덩어리 자료(간격 6, ARI 평균 0.81)에서만 충족했습니다. 대분류의 4덩어리 자료는 ARI 평균이 최대 0.74, 12유형은 최대 0.66이라 이 기준으로 평가할 수 없었습니다.

무작위 B가 실제보다 높은 이유

대분류에서 B가 높은 것은 군집이 나뉜 형태의 차이와 가장 관련이 커 보입니다. 다만 결과를 본 뒤에 나눠 본 사후 관찰이라 원인으로 확정하지는 않습니다.

가능한 원인	확인 결과	판단
표본 흔들림	실제 자료 부트스트랩 10회: 0.157~0.179 (평균 0.163)	아님
상관 재현 오차	보정한 B 10회: 평균 0.207 → 0.194	일부만 설명

가능한 원인	확인 결과	판단
군집 크기	보정한 B에서 최소 군집 19% 이상이면 0.175(3회), 미만이면 0.203(7회)	가장 관련이 큼

실제 자료의 최소 군집은 19.6%로 비교적 고릅습니다. 고르게 나뉜 경우끼리 비교하면 격차가 0.01 정도로 줄어듭니다. 실제 자료가 왜 고르게 나뉘는지는 아직 모릅니다.

권고 표현과 한계

문서에는 아래 문장을 쓰고, "이어진 분포입니다"처럼 단정하는 표현은 피하는 것을 권합니다.

- **보고서:** "실루엣 기준으로 변수별 분포와 상관관계만으로 설명되는 수준을 넘는 구조는 확인되지 않았습니다. 이 검정은 간격 4 SD 이상의 덩어리는 잡아내지만 약한 구조는 놓칠 수 있습니다."
- **발표:** "뚜렷하게 떨어진 무리는 확인되지 않았지만, 12유형은 안정적으로 다시 나오고 부족 영양소 안내에 쓸모 있는 구분입니다."

남은 한계는 다음과 같습니다.

- **심은 구조가 제한적입니다.** 크기가 같은 덩어리만 시험했고, 12덩어리는 2단계 절차에 가장 유리하게 배치했습니다. 실제 구조가 다르면 검출력은 더 낮을 수 있습니다.
- **반복이 적습니다.** 가짜 자료는 종류별 20회, 간격별 시험은 5회라 검출률은 대략적인 값입니다.
- **세분화 변수를 고정했습니다.** 실제 자료에서 탐색해 고른 조합이라 실제 자료에 유리합니다. 그런데도 실제 값이 기준을 넘지 못했습니다.
- **지표가 실루엣뿐입니다.** 다른 군집 지표로도 같은 결론이 나오는지는 확인하지 않았습니다.